

AWS en pratique

Instances EC2, volumes et images, répartition de charge, élasticité

Lancer et administrer une instance EC2. Volumes, images et sauvegardes. Répartition de charge. Élasticité.

Instance

AMI, type, démarrage

Accès et achat

Session Manager, Spot

Volumes

EBS, chiffrement

Images

snapshots, AMI, modèles

Load balancers

ALB, NLB, HTTPS

Élasticité

Auto Scaling, sans état

Support de formation, version 1.3, octobre 2026. Parcours « AWS en pratique ». Fait suite au support « Filtrage et dépannage réseau ».

L'instance EC2

- Choisir une AMI et un type d'instance.
- Expliquer le rôle de la paire de clés, du user data et des métadonnées.
- Se connecter sans port SSH ouvert, par Session Manager.
- Donner des droits à une instance par un rôle.
- Comparer les modes d'achat : à la demande, Spot, Savings Plans.

Volumes et images

- Choisir un type de volume EBS.
- Agrandir et chiffrer un volume.
- Expliquer le fonctionnement des snapshots.
- Créer une AMI personnalisée.
- Décrire un lancement dans un modèle de lancement.

Répartition de charge

- Décrire listeners, règles, target groups et health checks d'un Application Load Balancer.
- Dire quand préférer un Network Load Balancer.
- Mettre en place HTTPS avec un certificat ACM.

Élasticité

- Régler la capacité minimale, voulue et maximale d'un Auto Scaling group.
- Mettre en place un suivi de cible et une action planifiée.
- Concevoir des instances sans état.

Prérequis. Les supports précédents : rôles IAM, AWS CLI, VPC à trois niveaux, security groups chaînés, Session Manager.

Fil rouge. Les serveurs applicatifs de UtopiosShop : des instances privées, derrière un load balancer, lancées à partir d'une image et d'un modèle, et gérées par un Auto Scaling group.

L'instance EC2	
L'instance	AMI, type, clés, cycle de vie.
Démarrage	User data, métadonnées.
Accès et rôle	Session Manager, instance profile.
Modes d'achat	À la demande, Spot, Savings Plans.

Répartition de charge	
ALB	Listeners, règles, target groups, health checks.
NLB	Couche 4, adresses fixes.
HTTPS	TLS, certificats ACM.

Volumes et images	
Volumes EBS	Types, redimensionnement, chiffrement.
Snapshots et AMI	Sauvegardes, images personnalisées.
Modèles	Launch templates, versions.

Élasticité	
ASG	Capacités, zones, remplacement.
Politiques	Suivi de cible, planification.
Sans état	Sortir l'état des instances.

Convention. Les tarifs cités sont ceux de la région us-east-1, hors taxes, à titre d'ordre de grandeur : ils diffèrent légèrement à Paris et évoluent. La page de tarification de chaque service fait foi.

L'instance EC2, partie 1

L'instance EC2

Un serveur virtuel loué à la seconde : ce que l'on choisit à son lancement, et ce qu'il devient ensuite.

- Anatomie d'une instance
- L'AMI
- Le type d'instance
- La paire de clés
- Le cycle de vie
- Lancer une instance

Définition : Amazon EC2 (Elastic Compute Cloud)

Service qui fournit des serveurs virtuels à la demande, dont on choisit le système, la puissance et l'emplacement réseau, et que l'on paie à la durée d'utilisation.

Définition : instance

Serveur virtuel EC2 en cours d'existence. Elle possède un identifiant (`i-0abc...`), tourne dans un sous-réseau d'un VPC et se facture à la seconde.

Ce qui est à votre charge

- Le système d'exploitation : mises à jour, correctifs, durcissement.
- Les logiciels installés et leur configuration.
- Les données, leur sauvegarde, leur chiffrement.
- Le filtrage réseau et les droits accordés à l'instance.
- La disponibilité : une instance seule peut tomber.


Quand choisir EC2

- Besoin de maîtriser le système : noyau, pilotes, logiciel à licence.
- Application existante qui ne tourne ni en conteneur ni en fonction.
- Charge constante et prévisible, où le coût par heure est le plus bas.

Sinon, regarder d'abord plus managé : Fargate, Lambda, RDS plutôt qu'une base installée à la main.

Rappel du modèle de responsabilité. EC2 est de l'infrastructure : AWS garantit le matériel, le réseau et l'hyperviseur ; tout ce qui se trouve à l'intérieur de l'instance vous appartient.

Schéma : ce que l'on choisit au lancement



Lecture. Lancer une instance, c'est répondre à six questions : avec quel système démarre-t-elle, quelle puissance a-t-elle, sur quels disques, dans quel réseau, qui y accède et avec quels droits, et que fait-elle à son premier démarrage. Tout le reste du chapitre détaille ces six choix.

Définition : AMI (Amazon Machine Image)

Modèle à partir duquel une instance est créée. Elle contient l'image du volume racine (système et logiciels), la description des volumes à attacher et les permissions de lancement.

Origine	Contenu
AWS	Amazon Linux, Windows Server, et les distributions courantes publiées avec leurs éditeurs : Ubuntu, Debian, Red Hat, SUSE.
AWS Marketplace	Images d'éditeurs, souvent avec un logiciel préinstallé et parfois une licence facturée à l'heure.
Communauté	Images publiées par n'importe quel compte. Aucune garantie : à éviter sans vérification.
Les vôtres	AMI personnalisées, créées à partir de vos instances.

Propriétés

- **Régionale** : une AMI existe dans une région. Son identifiant (`ami-...`) diffère d'une région à l'autre pour le même système.
- **Liée à une architecture** : x86_64 ou arm64. Elle doit correspondre au type d'instance.
- **Datée** : les éditeurs publient régulièrement de nouvelles versions corrigées.

Ne pas écrire un identifiant d'AMI en dur. Il change à chaque mise à jour et d'une région à l'autre. On le récupère au moment du lancement, comme le montre la diapositive suivante.

AMI	À savoir
Amazon Linux 2023	Distribution d'AWS, gratuite. Agent SSM et AWS CLI préinstallés, IMDSv2 imposé. Utilisateur <code>ec2-user</code> , paquets avec <code>dnf</code> .
Ubuntu Server LTS	Très répandue. Utilisateur <code>ubuntu</code> , paquets avec <code>apt</code> .
Windows Server	Licence comprise dans le prix horaire, sensiblement plus élevé.
Images optimisées	Pour ECS, EKS, le calcul sur GPU : fournies par AWS, prêtes pour leur usage.

Dans la formation : Amazon Linux 2023, sauf mention contraire.


\$ Récupérer l'identifiant de la dernière AMI Amazon Linux 2023

```
# AWS publie cet identifiant dans un paramètre public,
# tenu à jour dans chaque région
P=/aws/service/ami-amazon-linux-latest
AMI_ID=$(aws ssm get-parameter \
  --name $P/al2023-ami-kernel-default-x86_64 \
  --query Parameter.Value --output text)
echo $AMI_ID

# Variante pour processeur ARM (Graviton)
aws ssm get-parameter \
  --name $P/al2023-ami-kernel-default-arm64 \
  --query Parameter.Value --output text

# Décrire une AMI : nom, architecture, date
aws ec2 describe-images --image-ids $AMI_ID --query \
  'Images[0].[Name,Architecture,CreationDate]' --output text
```

Schéma : lire le nom d'un type d'instance



Se lit : usage général, septième génération, processeur Graviton (ARM), taille large.

Définition : type d'instance

Combinaison de processeur, de mémoire, de stockage et de débit réseau proposée par EC2. Il fixe la puissance de l'instance et son prix horaire.

Lettre	Signification
g	Processeur AWS Graviton (ARM).
i, a	Processeur Intel, AMD.
d	Disque local NVMe.
n	Réseau renforcé.


Les familles de types d'instance

Famille	Catégorie	Caractéristique	Usages
T	Usage général, à crédits	Puissance de base modeste, pointes permises par des crédits CPU. Les moins chères.	Développement, petits sites, services peu sollicités.
M	Usage général	Équilibre processeur et mémoire : 4 Gio par vCPU.	Serveurs applicatifs, la plupart des charges.
C	Calcul	Processeur privilégié : 2 Gio par vCPU.	Calcul, encodage, serveurs web très sollicités.
R, X	Mémoire	8 Gio par vCPU et davantage.	Bases de données, caches, analyse en mémoire.
I, D	Stockage	Disques locaux rapides ou volumineux.	Bases NoSQL, entrepôts de données.
G, P	Calcul accéléré	Cartes graphiques.	Apprentissage automatique, rendu.

Taille	vCPU	Mémoire (famille M)
large	2	8 Gio
xlarge	4	16 Gio
2xlarge	8	32 Gio
4xlarge	16	64 Gio

Règle des tailles. Chaque taille double la précédente, en ressources comme en prix. Deux `large` coûtent autant qu'un `xlarge` : à puissance égale, plusieurs petites instances réparties sur deux zones valent mieux qu'une grosse.

Schéma : les instances T et leurs crédits CPU



Sans crédit : l'instance est ramenée au niveau de base, ou facturée en supplément en mode « unlimited ».

Définition : instance à performance modulable (burstable)

Instance de la famille T, qui dispose d'un niveau de processeur de base et accumule des crédits quand elle l'utilise peu, pour les dépenser lors des pointes.

Le piège. Une instance T sollicitée en continu au-delà de son niveau de base épuise ses crédits. En mode « unlimited », celui par défaut des T3 et T4g, elle continue mais chaque heure de dépassement est facturée : elle finit par coûter plus cher qu'une instance M.

Choisir un type d'instance

Démarche

1. Partir d'une famille d'usage général : **T** pour une charge faible ou irrégulière, **M** pour une charge soutenue.
2. Prendre la dernière génération disponible : plus rapide, et souvent moins chère.
3. Commencer petit, mesurer, ajuster : changer de type demande un simple arrêt et redémarrage.
4. Changer de famille seulement si une ressource limite : processeur (C), mémoire (R).

Définition : Graviton

Processeurs ARM conçus par AWS. À performance comparable, les instances Graviton coûtent environ 20 % de moins ; elles exigent une AMI et des logiciels compilés pour arm64.

Type	vCPU	Mémoire	Prix horaire indicatif
t3.micro	2	1 Gio	0,0104 \$
t3.medium	2	4 Gio	0,0416 \$
t4g.medium	2	4 Gio	0,0336 \$
m7g.large	2	8 Gio	0,0816 \$
m7i.large	2	8 Gio	0,1008 \$

Linux, à la demande, région us-east-1.

Définition : vCPU

Processeur virtuel : un fil d'exécution d'un cœur physique sur les instances Intel et AMD, un cœur entier sur les instances Graviton.

Outil. AWS Compute Optimizer observe l'utilisation réelle des instances et recommande un type mieux adapté, à la hausse comme à la baisse.

**Définition : paire de clés (key pair)**


Couple de clés cryptographiques servant à l'authentification SSH : AWS conserve la clé publique et la place sur l'instance, vous détenez la clé privée.

À savoir

Formats ED25519 ou RSA. La paire se choisit au lancement et ne se change pas simplement ensuite. Sous Windows, elle sert à déchiffrer le mot de passe administrateur. Avec Session Manager, **elle devient facultative** : on peut lancer une instance sans aucune clé.

L'instance EC2

Schéma : le cycle de vie d'une instance



	Arrêt (stop)	Suppression (terminate)
Volumes EBS	Conservés, facturés.	Volume racine supprimé par défaut.
Adresse privée	Conservée.	Libérée.
Adresse publique automatique	Perdue.	Perdue.
Disques locaux, mémoire	Perdus.	Perdus.

Facturation. À la seconde, avec une minute au minimum, tant que l'instance est « running ». Arrêtée, elle ne coûte plus de calcul ; ses volumes et ses Elastic IP restent facturés. **Protection.** L'option « termination protection » empêche une suppression accidentelle.

L'instance EC2

Console : lancer une instance

aws EC2 > Instances > Launch an instance

Name

user7-web-01

Amazon Machine Image

Amazon Linux 2023 AMI (64-bit x86) ▼

Instance type

t3.micro ▼

Key pair

Proceed without a key pair ▼

VPC / Subnet

user7-vpc / user7-subnet-prive-a ▼

Auto-assign public IP

Disable ▼

Security groups

user7-sg-app ▼

Storage

1 x 8 GiB gp3, Encrypted

IAM instance profile

user7-role-ec2 ▼

Metadata version

V2 only (token required) ▼

User data

#!/bin/bash ...

Launch instance

Rubrique	Point d'attention
Key pair	Inutile avec Session Manager.
Network settings	Cliquer sur Edit : par défaut, l'assistant propose le VPC par défaut et crée un security group ouvert en SSH.
Storage	Type gp3, chiffrement activé.
Advanced details	Rôle d'instance, version des métadonnées, user data : tout ce qui compte pour la suite se trouve dans cette rubrique repliée.
Summary	« Number of instances » : vérifier avant de valider.

Les valeurs par défaut de l'assistant conviennent à un premier essai, pas à un déploiement : sous-réseau public, adresse publique, port 22 ouvert. C'est l'inverse de ce que l'on veut.

Ligne de commande : lancer une instance

```
$ Prérequis : AWS CLI connectée ; sous-réseau privé (PRIV_A), security group (SG_APP) et instance profile user7-role-ec2 existants ; remplacer user7

# 1. Identifiant de la dernière AMI Amazon Linux 2023
AMI_ID=$(aws ssm get-parameter --name /aws/service/ami-amazon-linux-latest/al2023-ami-kernel-default-x86_64 \
--query Parameter.Value --output text)

# 2. Lancer l'instance : pas de clé, pas d'adresse publique, métadonnées en version 2, volume chiffré
INSTANCE=$(aws ec2 run-instances --image-id $AMI_ID --instance-type t3.micro \
--subnet-id $PRIV_A --security-group-ids $SG_APP --no-associate-public-ip-address \
--iam-instance-profile Name=user7-role-ec2 \
--metadata-options HttpTokens=required,HttpEndpoint=enabled \
--block-device-mappings 'DeviceName=/dev/xvda,Ebs={VolumeSize=8,VolumeType=gp3,Encrypted=true}' \
--user-data file:///userdata.sh \
--tag-specifications 'ResourceType=instance,Tags=[{Key=Name,Value=user7-web-01},{Key=Owner,Value=user7}]' \
'ResourceType=volume,Tags=[{Key=Name,Value=user7-web-01-root},{Key=Owner,Value=user7}]' \
--query 'Instances[0].InstanceId' --output text)

# 3. Attendre qu'elle soit en service, puis vérifier
aws ec2 wait instance-status-ok --instance-ids $INSTANCE
aws ec2 describe-instances --instance-ids $INSTANCE --output table \
--query 'Reservations[0].Instances[0].[InstanceId,State.Name,InstanceType,PrivateIpAddress,Placement.AvailabilityZone]'

# 4. Arrêter, redémarrer, supprimer
aws ec2 stop-instances --instance-ids $INSTANCE
aws ec2 start-instances --instance-ids $INSTANCE
aws ec2 terminate-instances --instance-ids $INSTANCE
```

Fichier requis. `userdata.sh` doit exister dans le dossier courant ; un exemple figure dans la partie suivante. Sans lui, retirer la ligne `--user-data`.

Erreur	Conséquence	Correction
AMI x86_64 avec un type Graviton, ou l'inverse	Lancement refusé.	Accorder l'architecture de l'AMI et celle du type.
Identifiant d'AMI copié d'une autre région	<code>InvalidAMIID.NotFound</code> .	Le récupérer par le paramètre public.
Instance lancée dans le VPC par défaut	Adresse publique, security group ouvert.	Toujours préciser sous-réseau et security group.
Clé privée perdue	Plus d'accès SSH.	Session Manager ; ne plus dépendre des clés.
Instance T sous charge continue	Lenteur, ou surcoût en mode unlimited.	Passer à une famille M ou C.
Instance arrêtée « pour ne plus payer »	Les volumes restent facturés.	La supprimer si elle ne sert plus, après snapshot.
Suppression d'une instance qui contenait des données	Volume racine détruit.	Données sur un volume séparé, snapshots, protection contre la suppression.
Quota de vCPU atteint	<code>VcpuLimitExceeded</code> .	Demander une hausse dans Service Quotas.

Traiter les instances comme du consommable. Rien d'irremplaçable ne doit vivre sur une instance : la configuration vient de l'image et du user data, les données d'une base ou d'un stockage géré. Une instance qui tombe se remplace, elle ne se répare pas.

L'instance EC2, partie 2

Le démarrage : user data et métadonnées

Comment une instance se configure toute seule à sa naissance, et comment elle se renseigne sur elle-même.

- Le user data
- cloud-init
- Écrire et déboguer un script de démarrage
- Le service de métadonnées
- IMDSv2
- Ce que l'on y trouve

Définition : user data

Données fournies au lancement d'une instance, le plus souvent un script, que le système exécute automatiquement à son premier démarrage pour s'installer et se configurer.

À quoi il sert

- Installer des paquets et appliquer les mises à jour.
- Déposer des fichiers de configuration.
- Démarrer un service.
- Récupérer le code de l'application depuis S3 ou un dépôt.
- Enregistrer l'instance auprès d'un outil de supervision.

Objectif : qu'une instance lancée par un automate soit opérationnelle sans intervention humaine.

Règle	Détail
Exécution	Une seule fois, au premier démarrage.
Droits	Ceux de <code>root</code> : pas de <code>sudo</code> à écrire.
Taille	16 Ko au plus.
Formats	Script commençant par <code>#!</code> , ou directives <code>#cloud-config</code> .
Interactivité	Aucune : toute commande qui attend une réponse bloque.

Aucun secret dans le user data. Il est lisible depuis l'instance par n'importe quel processus, et depuis l'API par quiconque a le droit de décrire l'instance. Les secrets se lisent dans Secrets Manager, grâce au rôle de l'instance.



Aux démarrages suivants, le script n'est pas rejoué.

Tant qu'il s'exécute, l'instance est « running » mais l'application n'est pas encore disponible.

Définition : cloud-init

Programme présent dans la plupart des images Linux du cloud, qui configure l'instance à son premier démarrage : nom d'hôte, clé SSH, et exécution du user data.

Conséquence pour un load balancer. Entre « running » et « application prête », il s'écoule le temps du script. C'est le contrôle de santé du load balancer, et non l'état de l'instance, qui dit quand lui envoyer du trafic.

\$ userdata.sh : un serveur web minimal sur Amazon Linux 2023

```
#!/bin/bash
# S'arrêter à la première erreur, tout journaliser
set -euxo pipefail

# Mises à jour et installation
dnf -y update
dnf -y install nginx

# Page d'accueil : montre quelle instance répond
TOKEN=$(curl -s -X PUT http://169.254.169.254/latest/api/token \
  -H "X-aws-ec2-metadata-token-ttl-seconds: 300")
ID=$(curl -s -H "X-aws-ec2-metadata-token: $TOKEN" \
  http://169.254.169.254/latest/meta-data/instance-id)
AZ=$(curl -s -H "X-aws-ec2-metadata-token: $TOKEN" \
  http://169.254.169.254/latest/meta-data/placement/availability-zone)
echo "<h1>UtopiosShop</h1><p>$ID dans $AZ</p>" \
  > /usr/share/nginx/html/index.html
echo "ok" > /usr/share/nginx/html/health

# Démarrage immédiat et à chaque redémarrage
systemctl enable --now nginx
```

yaml La même chose en cloud-config

```
#cloud-config
package_update: true
packages:
  - nginx
write_files:
  - path: /usr/share/nginx/html/health
    content: ok
runcmd:
  - systemctl enable --now nginx
```

Bonnes pratiques

- Script **idempotent** et court : le gros de l'installation appartient à l'image.
- `set -e` : un échec doit se voir, pas passer inaperçu.
- Options non interactives : `-y`.
- Versionner le script avec le code de l'application.

Définition : idempotent

Se dit d'une opération que l'on peut répéter sans changer le résultat obtenu la première fois.

\$ Sur l'instance (par Session Manager)

```
# Ce que le script a affiché, erreurs comprises
sudo cat /var/log/cloud-init-output.log
```

```
# Le déroulement détaillé de cloud-init
sudo tail -50 /var/log/cloud-init.log
```

```
# cloud-init a-t-il terminé, et sans erreur ?
cloud-init status --long
```

```
# Le user data tel que l'instance l'a reçu
TOKEN=$(curl -s -X PUT http://169.254.169.254/latest/api/token \
-H "X-aws-ec2-metadata-token-ttl-seconds: 300")
curl -s -H "X-aws-ec2-metadata-token: $TOKEN" \
http://169.254.169.254/latest/user-data
```

\$ Sans se connecter : la sortie console de l'instance

```
aws ec2 get-console-output --instance-id $INSTANCE \
--latest --output text | tail -40
```

Symptôme

Cause fréquente

Rien n'est installé

Première ligne absente ou erronée : le script doit commencer par `#!/bin/bash`.

Installation de paquets en échec

Pas de sortie vers Internet : ni NAT Gateway, ni endpoints.

Script interrompu au milieu

Une commande a échoué ; lire le journal.

Modification du user data sans effet

Il n'est joué qu'au premier démarrage.

Modifier un user data. Possible seulement instance arrêtée, et sans effet sur ce qui a déjà été exécuté. En pratique : on corrige le script et on relance une instance neuve.

Définition : service de métadonnées d'instance (IMDS)

Service local à chaque instance, joignable à l'adresse 169.254.169.254, qui lui fournit des informations sur elle-même : identifiant, adresses, zone, user data, identifiants de son rôle.

Chemin sous /latest/meta-data/	Renvoie
instance-id	L'identifiant de l'instance.
instance-type	Son type.
local-ipv4, public-ipv4	Ses adresses privée et publique.
placement/availability-zone	Sa zone de disponibilité.
placement/region	Sa région.
iam/security-credentials/<rôle>	Les identifiants temporaires de son rôle.
tags/instance/<clé>	Ses étiquettes, si l'option est activée.
spot/instance-action	Le préavis d'interruption d'une instance Spot.

Pourquoi c'est utile


- Un même script ou une même image s'adapte à l'instance sur laquelle il tourne, sans rien coder en dur.
- Les SDK et la CLI y trouvent automatiquement la région et les identifiants du rôle.
- Aucun droit IAM n'est requis : l'accès est réservé à l'instance elle-même.

Adresse particulière. 169.254.169.254 est une adresse « lien local » : elle ne sort pas de la machine. Elle n'est filtrée ni par les security groups ni par les tables de routage.

Sur l'instance, la commande `ec2-metadata` d'Amazon Linux affiche les mêmes informations sans manipuler de jeton.

Schéma : interroger les métadonnées avec IMDSv2

Adresse locale 169.254.169.254 : joignable uniquement depuis l'instance elle-même.



IMDSv1 répondait à un simple GET, sans jeton : une requête détournée par un attaquant suffisait.

IMDSv2 exige les deux étapes.

\$ Depuis l'instance

```
TOKEN=$(curl -s -X PUT http://169.254.169.254/latest/api/token \
-H "X-aws-ec2-metadata-token-ttl-seconds: 300")
curl -s -H "X-aws-ec2-metadata-token: $TOKEN" \
http://169.254.169.254/latest/meta-data/instance-id
```

Exiger IMDSv2. Option `HttpTokens=required` au lancement, ou `aws ec2 modify-instance-metadata-options` sur une instance existante. Les images récentes l'imposent déjà. Dans des conteneurs, porter la « hop limit » à 2 pour que la réponse traverse le réseau du conteneur.

Erreur	Conséquence	Correction
Mot de passe ou clé d'API dans le user data	Secret lisible par tout processus de l'instance et par l'API.	Secrets Manager ou Parameter Store, lus grâce au rôle.
User data qui installe tout, pendant dix minutes	Démarrage lent, montée en charge trop tardive.	Préparer une AMI ; ne garder que la configuration finale.
Script sans gestion d'erreur	Instance « running » mais à moitié configurée.	<code>set -e</code> , journal, contrôle de santé.
Commande interactive	Script bloqué indéfiniment.	Options <code>-y</code> , variables non interactives.
Fins de ligne Windows dans le script	« bad interpreter », rien ne s'exécute.	Enregistrer avec des fins de ligne Unix.
IMDSv1 laissé actif	Identifiants du rôle exposés à une requête détournée.	<code>HttpTokens=required</code> .
Appel aux métadonnées sans jeton sur IMDSv2	Erreur 401.	Demander d'abord le jeton.
Région ou identifiant codés en dur dans un script	Script inutilisable ailleurs.	Les lire dans les métadonnées.

L'instance EC2, partie 3

Accès et rôle d'instance

Se connecter à une instance sans ouvrir de port, et lui donner des droits sans lui confier de clé.

- Les façons de se connecter
- Session Manager
- Les trois conditions
- Le rôle d'instance
- Utilisation au quotidien
- Dépannage


Accès et rôle

Les façons de se connecter à une instance

Méthode	Port entrant	Authentification	Remarque
SSH classique	22, depuis votre adresse	Paire de clés	Demande une adresse joignable, donc un sous-réseau public ou un bastion. Clés à distribuer et à révoquer.
EC2 Instance Connect	22	Droits IAM ; clé temporaire poussée pour 60 secondes	Supprime la gestion des clés, pas le port ouvert.
Session Manager	Aucun	Droits IAM	Aucune adresse publique, aucune clé. Sessions journalisées. La méthode recommandée.
RDP (Windows)	3389	Mot de passe	Remplaçable par Fleet Manager, sans port ouvert.
Console série EC2	Aucun	Droits IAM et mot de passe du système	Dernier recours : instance qui ne démarre plus, réseau cassé.

Ce que l'on gagne à abandonner SSH. Plus de port 22 dans les security groups, plus de bastion à maintenir, plus de clés privées sur les postes, et une trace de qui s'est connecté à quoi.

Aller plus loin. En production, l'idéal est de ne plus se connecter du tout : les instances sont configurées par leur image et remplacées plutôt que modifiées. La session interactive sert au diagnostic.



1. L'agent SSM, sur l'instance, maintient une connexion sortante vers Systems Manager. C'est l'instance qui appelle, jamais l'inverse.

2. L'administrateur demande une session ; IAM vérifie qu'il en a le droit sur cette instance. Systems Manager relaie le terminal dans le canal déjà ouvert.

Les trois conditions de Session Manager

#	Condition	Détail	Vérification
1	L'agent SSM tourne	Préinstallé sur Amazon Linux, Ubuntu et Windows Server récents.	<code>systemctl status amazon-ssm-agent</code>
2	L'instance a les droits	Son rôle porte la politique gérée <code>AmazonSSMManagedInstanceCore</code> .	Onglet Security de l'instance.
3	L'instance joint Systems Manager	En HTTPS sortant : par une NAT Gateway, ou par les endpoints <code>ssm</code> et <code>ssmmessages</code> .	Règle sortante 443 du security group, route ou endpoints.

Côté administrateur

- Le droit IAM `ssm:StartSession` sur l'instance visée.
- Depuis la console : rien à installer.
- Depuis la CLI : le « Session Manager plugin », à installer une fois sur le poste.

Signe que tout est en place. L'instance apparaît dans **Systems Manager, Fleet Manager** avec l'état « Online », quelques minutes après son démarrage.

Si elle n'apparaît pas, la cause est presque toujours l'une des trois conditions, dans cet ordre de fréquence : le rôle manquant, puis l'absence de sortie réseau, puis l'agent.

Définition : rôle d'instance

Rôle IAM que le service EC2 endosse pour une instance. Les applications qui y tournent reçoivent ses identifiants temporaires, sans qu'aucune clé soit stockée sur la machine.

Définition : instance profile

Conteneur qui porte un rôle et que l'on attache à une instance. La console le crée en même temps que le rôle, sous le même nom ; en ligne de commande, ce sont deux objets.

Ce qu'il permet


- Session Manager : la politique `AmazonSSMManagedInstanceCore`.
- Lire un bucket, une table, un secret, écrire des journaux : les droits de l'application.
- Tout cela avec des identifiants renouvelés automatiquement, que le SDK trouve seul.

Règles

- Un rôle par application ou par fonction, jamais un rôle commun à tout le compte.
- Des politiques qui nomment les ressources : ce bucket, cette table.
- Une instance porte un seul rôle ; on peut le remplacer sans l'arrêter.
- Lancer une instance avec un rôle exige `iam:PassRole` sur ce rôle.

Rappel du chapitre « La CLI et les rôles ». Trust policy désignant `ec2.amazonaws.com`, politiques de permissions, identifiants temporaires délivrés par STS et remis par le service de métadonnées : le mécanisme est celui de tous les rôles de service.

Schéma : comment l'application obtient ses identifiants



1. Le SDK ou la CLI, ne trouvant ni variable ni fichier, interroge le service de métadonnées.

2. EC2 a endossé pour l'instance le rôle porté par son instance profile.

3. STS délivre des identifiants temporaires, mis à disposition et renouvelés avant expiration.

4. Le service de métadonnées les remet à l'application.

5. L'application signe ses appels : elle a les droits du rôle, ni plus ni moins.

\$ Prérequis : droits iam:CreateRole et iam:PassRole ; remplacer user7

1. Trust policy : le service EC2 peut endosser le rôle

```
cat > ec2-trust.json <<'EOF'
{"Version":"2012-10-17","Statement":[{"Effect":"Allow",
  "Principal":{"Service":"ec2.amazonaws.com"},"Action":"sts:AssumeRole"}]}
EOF
```

2. Le rôle, avec la politique nécessaire à Session Manager

```
aws iam create-role --role-name user7-role-ec2 --assume-role-policy-document file://ec2-trust.json
aws iam attach-role-policy --role-name user7-role-ec2 \
  --policy-arn arn:aws:iam::aws:policy/AmazonSSMManagedInstanceCore
```

3. L'instance profile, qui contient le rôle

```
aws iam create-instance-profile --instance-profile-name user7-role-ec2
aws iam add-role-to-instance-profile --instance-profile-name user7-role-ec2 --role-name user7-role-ec2
```

4. L'attacher à une instance existante (ou le désigner au lancement, option --iam-instance-profile)

```
aws ec2 associate-iam-instance-profile --instance-id $INSTANCE --iam-instance-profile Name=user7-role-ec2
```

5. Vérifier, depuis l'instance : quelle identité ses appels portent-ils ?

```
aws sts get-caller-identity
#   "Arn": "arn:aws:sts::123456789012:assumed-role/user7-role-ec2/i-0abc123def4567890"
```

Délai. Un instance profile créé à l'instant peut être refusé pendant quelques secondes au lancement d'une instance : la propagation d'IAM n'est pas immédiate. Dans un script, attendre une dizaine de secondes ou réessayer.

\$ Prérequis : Session Manager plugin installé sur le poste

```
# Instances visibles par Systems Manager
aws ssm describe-instance-information --output table \
  --query 'InstanceInformationList[].[
    InstanceId,PingStatus,PlatformName]'
```

```
# Ouvrir un terminal
aws ssm start-session --target $INSTANCE
```

```
# Rediriger un port : l'application de l'instance (8080)
# devient joignable sur http://localhost:8080
aws ssm start-session --target $INSTANCE \
  --document-name AWS-StartPortForwardingSession \
  --parameters '{"portNumber":["8080"],"localPortNumber":["8080"]}'
```

```
# Exécuter une commande sur une ou plusieurs instances
aws ssm send-command --instance-ids $INSTANCE \
  --document-name AWS-RunShellScript \
  --parameters 'commands=["systemctl status nginx"]'
```

Fonction

Usage

Session

Terminal interactif. L'utilisateur du système est `ssm-user`, avec `sudo`.

Redirection de port

Atteindre une application ou une base privée depuis son poste, sans rien exposer.

Run Command

Lancer une commande sur un parc d'instances, choisies par étiquette.

Journalisation

Chaque ouverture de session figure dans CloudTrail ; le contenu peut être envoyé vers CloudWatch Logs ou S3.

Dans la console. Page de l'instance, bouton **Connect**, onglet **Session Manager**. Si le bouton est grisé, l'instance n'est pas vue par Systems Manager : revoir les trois conditions.

Contrôle d'accès. Une politique IAM peut limiter `ssm:StartSession` aux instances portant une certaine étiquette : chacun n'accède qu'à ses machines.

Symptôme	Cause probable	Vérification
Instance absente de Fleet Manager	Aucun rôle, ou rôle sans <code>AmazonSSMManagedInstanceCore</code> .	Onglet Security de l'instance : « IAM Role ».
Rôle correct, instance toujours absente	Pas de sortie HTTPS : ni NAT Gateway ni endpoints.	Table de routage du sous-réseau ; règle sortante 443.
Rôle attaché après coup, sans effet	L'agent n'a pas encore réessayé.	Patienter, ou redémarrer l'instance.
« TargetNotConnected »	Agent arrêté, ou instance arrêtée.	État de l'instance, sortie console.
« AccessDenied » à l'ouverture de session	L'administrateur n'a pas <code>ssm:StartSession</code> .	Ses politiques IAM, pas celles de l'instance.
« SessionManagerPlugin is not found »	Plugin absent du poste.	L'installer, ou passer par la console.
L'application reçoit « Unable to locate credentials »	Aucun rôle attaché à l'instance.	<code>aws sts get-caller-identity</code> sur l'instance.
L'application reçoit « AccessDenied »	Le rôle n'a pas le droit demandé.	Lire l'action et la ressource dans le message.

Deux identités à ne pas confondre. Celle de l'**administrateur**, qui ouvre la session avec ses propres droits IAM ; celle de l'**instance**, dont le rôle sert à l'agent et aux applications. Un message d'erreur concerne toujours l'une ou l'autre.

L'instance EC2, partie 4

Les modes d'achat

La même instance peut coûter trois fois moins cher selon l'engagement que l'on prend et l'interruption que l'on accepte.

- Vue d'ensemble
- À la demande
- Instances Spot
- Savings Plans
- Combiner les modes
- Ce qui reste facturé

Trois façons de payer la même instance

	À la demande	Spot	Savings Plans
Principe	Payer à la seconde, sans engagement.	Utiliser la capacité inoccupée d'AWS, à prix réduit.	S'engager sur un montant horaire, pour 1 ou 3 ans.
Réduction	Aucune : c'est le tarif de référence.	Jusqu'à 90 %.	Jusqu'à 72 %.
Contrepartie	Le prix le plus élevé.	Interruption possible, avec 2 minutes de préavis.	Engagement dû, que l'on consomme ou non.
Pour quelle charge	Imprévisible, courte, nouvelle.	Interruptible, relançable, flexible.	Stable, connue, durable.
Changement technique	Aucun.	L'application doit tolérer l'interruption.	Aucun : c'est une remise sur la facture.

Ce qui ne change pas. Le matériel, la performance, le réseau, les fonctions : une instance Spot et une instance à la demande du même type sont rigoureusement identiques.

Deux natures différentes. Spot est une façon de **lancer** une instance. Un Savings Plan est une **remise** appliquée après coup aux instances à la demande : il ne se « lance » pas.

Définition : à la demande (On-Demand)

Mode d'achat par défaut : l'instance est facturée à la seconde d'utilisation, au tarif public, sans engagement ni paiement d'avance.

Quand l'utiliser

- Démarrage d'un projet, tant que la charge n'est pas connue.
- Environnements temporaires : test, formation, démonstration.
- Pointes imprévisibles, au-dessus de la base engagée.
- Applications qui ne supportent pas l'interruption et ne durent pas assez pour un engagement.

Durée d'un t3.medium**Coût indicatif****1 heure**

0,04 \$

Une journée de 8 heures

0,33 \$

Un mois, 8 h par jour ouvré

7 \$

Un mois complet (730 h)

30 \$

Premier levier d'économie. Avant tout engagement : éteindre ce qui ne sert pas. Un environnement de développement arrêté la nuit et le week-end coûte quatre fois moins.

Capacité non garantie. À la demande ne garantit pas qu'un type soit disponible dans une zone à l'instant voulu (`InsufficientInstanceCapacity`). Pour une garantie, il existe les réservations de capacité.

Schéma : le principe d'une instance Spot



Même machine, même performance : seule change la garantie de la conserver.

Définition : instance Spot

Instance lancée sur la capacité inutilisée d'EC2, à un prix très inférieur au tarif à la demande, qu'AWS peut reprendre à tout moment avec un préavis de deux minutes.

Le prix. Il n'y a plus d'enchères : le prix Spot évolue lentement selon l'offre et la demande, par type et par zone. On paie le prix courant, toujours inférieur ou égal au tarif à la demande.

Convient	Ne convient pas
Traitements par lots, calcul, rendu.	Base de données sur une seule instance.
Intégration continue, tests.	Application à état conservé en mémoire.
Serveurs web sans état derrière un load balancer.	Traitement long impossible à reprendre.
Nœuds de travail d'un cluster de conteneurs.	Composant unique dont l'arrêt coupe le service.
Environnements de développement.	Charge soumise à un délai strict.

Bonnes pratiques

- **Diversifier** : accepter plusieurs types et plusieurs zones. Plus le choix est large, plus l'interruption est rare.
- **Rester sans état** : rien d'important sur l'instance.
- **Écouter le préavis** : il arrive par EventBridge et par les métadonnées ; deux minutes pour terminer proprement.
- **Mélanger** : une base à la demande, un complément en Spot, dans un même Auto Scaling group.

\$ Lancer une instance en Spot : une option suffit

```
aws ec2 run-instances --image-id $AMI_ID \  
  --instance-type t3.micro --subnet-id $PRIV_A \  
  --instance-market-options 'MarketType=spot'
```

Définition : Savings Plan

Engagement à dépenser un montant fixe par heure en calcul, pendant un an ou trois ans, en échange d'une remise sur l'usage couvert par cet engagement.

	Compute Savings Plan	EC2 Instance Savings Plan
Remise maximale	Jusqu'à 66 %.	Jusqu'à 72 %.
S'applique à	EC2 de toute famille, taille, région et système ; Fargate ; Lambda.	Une famille d'instances dans une région.
Souplesse	Maximale.	Taille et système libres, famille et région figées.


Comment dimensionner. S'engager sur la **base** : ce qui tourne en permanence, jour et nuit. Cost Explorer propose un montant d'après l'historique de consommation.

Fonctionnement

- On s'engage sur un montant : par exemple **2 \$ par heure**.
- Chaque heure, l'usage est facturé au tarif réduit jusqu'à hauteur de l'engagement.
- Ce qui dépasse est facturé à la demande.
- Ce qui n'est pas consommé est perdu : l'engagement est dû.
- Paiement d'avance total, partiel ou nul : plus on avance, plus la remise est forte.

Et les instances réservées ? C'est l'ancien mécanisme d'engagement, lié à un type précis. Elles existent toujours ; les Savings Plans, plus souples à remise comparable, les ont largement remplacées.

Schéma : combiner les modes d'achat



Chaque tranche de la consommation est achetée au mode qui lui convient.

La base

Ce qui tourne toujours : couvert par un Savings Plan. C'est la part la plus sûre, donc celle où l'engagement ne coûte rien.

La part variable

Ce qui suit l'activité de la journée : à la demande, ajouté et retiré par l'Auto Scaling.

Les pics

Ce qui peut être interrompu sans dommage : en Spot, pour absorber les pointes au moindre coût.

Comparaison chiffrée, et ce qui reste facturé

Un t3.medium, un mois complet	Ordre de grandeur
À la demande	30 \$
Savings Plan, 1 an, sans avance	20 \$
Savings Plan, 3 ans, payé d'avance	12 \$
Spot	9 à 12 \$
À la demande, éteint hors heures ouvrées	7 \$

Estimations pour us-east-1 ; les remises réelles dépendent du type, de la région et de la date.

Lecture. L'instance éteinte quand elle ne sert pas reste la moins chère. L'engagement et Spot viennent après, pour ce qui doit tourner.

Poste	Instance arrêtée	Instance supprimée
Calcul	Non facturé	Non facturé
Volumes EBS	Facturés	Facturés s'ils sont conservés
Snapshots, AMI	Facturés	Facturés
Elastic IP	Facturée	Facturée tant qu'elle est allouée
Savings Plan	Dû	Dû

Les restes. Après un nettoyage, vérifier les volumes à l'état « available », les snapshots orphelins et les Elastic IP non associées : ce sont eux qui grossissent une facture sans que rien ne tourne.

Suivi. Cost Explorer, filtré sur le service EC2 et regroupé par « Purchase option », montre la part de chaque mode et le taux d'utilisation des engagements.

Ce qu'il faut retenir

- Une instance se définit par son AMI, son type, son stockage, son réseau, son rôle et son user data.
- Le nom d'un type se lit : famille, génération, attributs, taille.
- Le user data s'exécute une fois, en root, au premier démarrage ; il ne contient aucun secret.
- Les métadonnées renseignent l'instance sur elle-même ; IMDSv2 est à exiger.
- Session Manager : aucun port, aucune clé ; un agent, un rôle, une sortie HTTPS.
- Le rôle d'instance remplace toute clé d'accès sur la machine.
- À la demande pour l'imprévu, Savings Plans pour la base, Spot pour l'interruptible.

1. Que signifie c7g.xlarge ?

2. Quand le user data s'exécute-t-il ?

3. Quelles sont les trois conditions de Session Manager ?

4. Que devient l'adresse publique d'une instance arrêtée ?

5. Pourquoi exiger IMDSv2 ?

6. Quel préavis avant l'interruption d'une instance Spot ?

7. Sur quelle part de la charge prendre un Savings Plan ?

Cliquer sur une question pour afficher la réponse.

Volumes et images, partie 1

Les volumes EBS

Le disque dur des instances : un stockage en réseau, persistant, que l'on choisit, agrandit et chiffre à volonté.

- Définition et propriétés
- EBS et disque local
- Les types de volumes
- IOPS et débit
- Redimensionnement à chaud
- Chiffrement

Qu'est-ce qu'un volume EBS

Définition : Amazon EBS (Elastic Block Store)

Service de stockage en mode bloc pour les instances EC2 : il fournit des volumes qui se comportent comme des disques durs, attachés par le réseau.

Définition : volume

Disque virtuel EBS, d'une taille et d'un type choisis, que l'on attache à une instance. Le système le voit comme un disque à partitionner et à formater.

Propriété	Conséquence
Persistant	Il survit à l'arrêt de l'instance, et à sa suppression si on le demande.
Attaché par le réseau	Il se détache d'une instance et se rattache à une autre en quelques secondes.
Lié à une zone	Il ne s'attache qu'à une instance de la même zone de disponibilité.
Répliqué dans sa zone	AWS en garde plusieurs copies : la panne d'un disque physique est invisible.
Une instance à la fois	Sauf cas particulier, un volume n'est attaché qu'à une instance.
Facturé à la taille provisionnée	On paie les gigaoctets réservés, qu'ils soient remplis ou non.


Définition : stockage en mode bloc

Stockage présenté comme une suite de blocs numérotés, sans notion de fichier. C'est le système d'exploitation qui y crée un système de fichiers.

Trois familles de stockage. Bloc (EBS) : le disque d'une machine. Fichier (EFS) : un dossier partagé entre plusieurs machines. Objet (S3) : des fichiers accessibles par une API, sans disque ni montage.

Répliqué ne veut pas dire sauvegardé. La réplication protège d'une panne matérielle, pas d'une suppression, d'une corruption ni de la perte de la zone. Pour cela, il faut des snapshots.

Schéma : un volume, une zone

**Définition : volume racine**

Volume qui contient le système d'exploitation, créé à partir de l'AMI au lancement. Par défaut, il est supprimé avec l'instance (option DeleteOnTermination).

Séparer système et données. Un volume de données distinct du volume racine survit à la suppression de l'instance, se sauvegarde à part, se rattache à une instance de remplacement et s'agrandit sans toucher au système.

	Volume EBS	Disque local (instance store)
Emplacement	Stockage en réseau, dans la zone.	Disque physique du serveur qui héberge l'instance.
Durée de vie	Indépendante de l'instance.	Celle de l'instance sur ce serveur.
À l'arrêt de l'instance	Données conservées.	Données perdues.
Panne du serveur physique	Sans effet : le volume se rattache ailleurs.	Données perdues.
Performance	Élevée, réglable.	Très élevée : aucun passage par le réseau.
Coût	Au gigaoctet provisionné.	Compris dans le prix de l'instance.
Disponibilité	Tous les types d'instance.	Certains types, repérés par la lettre « d ».
Snapshots	Oui.	Non.

Définition : instance store

Stockage temporaire fourni par des disques physiquement attachés au serveur hôte. Ses données disparaissent à l'arrêt, à l'hibernation ou à la suppression de l'instance.

Usage du disque local. Données reconstituibles : cache, fichiers temporaires, tampons de calcul, réplica d'une base distribuée qui se resynchronise seul. Jamais l'unique exemplaire d'une donnée.

Définition : IOPS

Nombre d'opérations de lecture ou d'écriture par seconde. Mesure la capacité d'un disque à traiter beaucoup de petites opérations.

Définition : débit (throughput)

Volume de données lu ou écrit par seconde, en Mio/s. Mesure la capacité d'un disque à transférer de gros blocs à la suite.

Lien entre les deux. Débit = IOPS × taille des opérations. 3 000 opérations de 16 Kio font environ 47 Mio/s ; 500 opérations de 256 Kio font 125 Mio/s.

Charge	Ce qui compte	Exemples
Nombreuses petites opérations aléatoires	IOPS	Base de données transactionnelle, volume système.
Grandes lectures et écritures séquentielles	Débit	Journaux, entrepôt de données, traitement de fichiers.

Où se trouve la limite

- Le **volume** a ses plafonds d'IOPS et de débit.
- L'**instance** a les siens, selon son type : un petit type ne peut pas exploiter un volume très rapide.

La performance réelle est le plus petit des deux. Les métriques CloudWatch du volume montrent si l'un des plafonds est atteint.

Les types de volumes

Type	Support	Performance	Taille	Usage
gp3	SSD usage général	3 000 IOPS et 125 Mio/s inclus ; jusqu'à 80 000 IOPS et 2 000 Mio/s en option.	1 Gio à 64 Tio	Le choix par défaut : système, applications, la plupart des bases.
gp2	SSD, génération précédente	3 IOPS par Gio : la performance dépend de la taille.	1 Gio à 16 Tio	À migrer vers gp3, moins cher et plus souple.
io2 Block Express	SSD haute performance	Jusqu'à 256 000 IOPS et 4 000 Mio/s, garantis ; durabilité renforcée.	4 Gio à 64 Tio	Bases critiques, très sollicitées.
st1	Disque magnétique à débit optimisé	Jusqu'à 500 Mio/s ; peu d'IOPS.	125 Gio à 16 Tio	Gros volumes lus séquentiellement : journaux, données analytiques.
sc1	Disque magnétique froid	Jusqu'à 250 Mio/s.	125 Gio à 16 Tio	Données rarement lues, au moindre coût.

Règle simple. gp3, sauf raison précise. On ajoute des IOPS ou du débit si les mesures le demandent ; on ne passe à io2 que pour une base qui exige une performance garantie très élevée.

Les disques magnétiques (st1, sc1) ne peuvent pas servir de volume racine, et leur taille minimale est de 125 Gio.

Ce qui distingue gp3

- La performance est **indépendante de la taille** : un volume de 20 Gio a les mêmes 3 000 IOPS de base qu'un volume de 2 Tio.
- Taille, IOPS et débit se règlent **séparément**, et se modifient à chaud.
- Environ 20 % moins cher que gp2 au gigaoctet.

Avec gp2, il fallait surdimensionner le volume pour obtenir des IOPS : 1 Tio pour 3 000 IOPS. Avec gp3, on paie la taille dont on a besoin et, à part, la performance voulue.

Migration. Un volume gp2 se convertit en gp3 par une simple modification, sans interruption.

Élément	Tarif indicatif
gp3, stockage	0,08 \$ par Gio et par mois
gp3, IOPS au-delà de 3 000	0,005 \$ par IOPS et par mois
gp3, débit au-delà de 125 Mio/s	0,04 \$ par Mio/s et par mois
st1	0,045 \$ par Gio et par mois
Snapshot	0,05 \$ par Gio et par mois

Exemple mensuel	Coût
Volume racine gp3 de 8 Gio	0,64 \$
Volume gp3 de 100 Gio	8 \$
Le même, porté à 6 000 IOPS	23 \$

Facturé même détaché. Un volume à l'état « available », qui n'est attaché à rien, coûte autant qu'un volume en service.

Créer, attacher et monter un volume

\$ Prérequis : INSTANCE défini, instance en zone eu-west-3a ; remplacer user7

1. Créer un volume gp3 de 100 Gio, chiffré, dans la zone de l'instance

```
VOL=$(aws ec2 create-volume --availability-zone eu-west-3a --size 100 --volume-type gp3 --encrypted \
--tag-specifications 'ResourceType=volume,Tags=[{Key=Name,Value=user7-web-01-data},{Key=Owner,Value=user7}]' \
--query VolumeId --output text)
aws ec2 wait volume-available --volume-ids $VOL
```

2. L'attacher à l'instance

```
aws ec2 attach-volume --volume-id $VOL --instance-id $INSTANCE --device /dev/sdf
```

\$ Puis, sur l'instance (par Session Manager)

3. Repérer le nouveau disque : sur les instances récentes, il apparaît en nvme
lsblk

4. Créer un système de fichiers (UNIQUEMENT sur un volume vide), puis monter


```
sudo mkfs -t xfs /dev/nvme1n1
sudo mkdir -p /data
sudo mount /dev/nvme1n1 /data
```

5. Montage automatique au redémarrage, par l'identifiant du système de fichiers

```
UUID=$(sudo blkid -s UUID -o value /dev/nvme1n1)
echo "UUID=$UUID /data xfs defaults,nofail 0 2" | sudo tee -a /etc/fstab
```

Deux précautions. `mkfs` efface tout : ne jamais le lancer sur un volume restauré d'un snapshot. Dans `/etc/fstab`, utiliser l'UUID et l'option `nofail` : le nom `nvme1n1` peut changer d'un démarrage à l'autre, et un volume absent ne doit pas empêcher l'instance de démarrer.

Schéma : agrandir un volume à chaud



AWS agrandit le disque ; c'est au système d'exploitation de s'en servir.

On peut agrandir, changer de type ou de performance, mais jamais réduire la taille.

\$ Depuis le poste, puis sur l'instance

```
aws ec2 modify-volume --volume-id $VOL --size 200
aws ec2 describe-volumes-modifications --volume-ids $VOL \
  --query 'VolumesModifications[0].[ModificationState,Progress]'
```


```
# Sur l'instance : volume sans partition, formaté en xfs
sudo xfs_growfs /data
df -h /data
```

Définition : Elastic Volumes

Fonction d'EBS qui permet de modifier la taille, le type, les IOPS et le débit d'un volume attaché, sans arrêter l'instance ni démonter le volume.

Limites. La taille ne peut qu'augmenter. Après une modification, il faut attendre environ six heures avant d'en faire une autre sur le même volume.

Schéma : le chiffrement d'un volume



Définition : chiffrement au repos

Chiffrement des données telles qu'elles sont stockées sur le support. Quiconque accèderait au disque physique ne lirait que des données illisibles.

Ce qui est chiffré

Les données du volume, les échanges entre l'instance et le volume, tous les snapshots du volume, et tous les volumes créés à partir de ces snapshots. La clé reste dans AWS KMS ; son usage est tracé dans CloudTrail.

Le réglage à activer une fois

- **EBS encryption by default** : réglage du compte, par région.
- Une fois activé, tout nouveau volume et toute copie de snapshot sont chiffrés, sans qu'on ait à y penser.
- Il ne chiffre pas les volumes existants.

\$ Activer et vérifier, dans la région courante

```
aws ec2 enable-ebs-encryption-by-default
aws ec2 get-ebs-encryption-by-default

# Volumes non chiffrés qui subsistent
aws ec2 describe-volumes \
  --filters Name=encrypted,Values=false \
  --query 'Volumes[].[VolumeId,Size,State]' --output table
```

Clé	Caractéristique
Clé gérée par AWS (<code>aws/ebs</code>)	Aucune gestion. Suffit dans la plupart des cas. Ne permet pas de partager un snapshot chiffré avec un autre compte.
Clé gérée par le client	Vous définissez qui peut l'utiliser, vous pouvez la désactiver, et partager des snapshots chiffrés entre comptes.

Aucune raison de s'en passer. Le chiffrement EBS est gratuit, transparent, sans effet mesurable sur les performances, et exigé par tous les référentiels de sécurité.

Droits. Pour utiliser un volume chiffré par une clé gérée par le client, celui qui lance l'instance, et les services comme l'Auto Scaling, doivent avoir le droit d'utiliser cette clé. Sinon l'instance s'arrête aussitôt lancée.

Schéma : chiffrer un volume existant



Un volume existant ne se chiffre pas sur place : on passe par un snapshot.

\$ Prérequis : VOL contient l'identifiant du volume non chiffré

```
SNAP=$(aws ec2 create-snapshot --volume-id $VOL \
  --description "avant chiffrement" \
  --query SnapshotId --output text)
aws ec2 wait snapshot-completed --snapshot-ids $SNAP

# Un volume chiffré peut être créé directement
# à partir du snapshot non chiffré
aws ec2 create-volume --snapshot-id $SNAP --encrypted \
  --availability-zone eu-west-3a --volume-type gp3
```

Raccourci. Il n'est pas obligatoire de copier le snapshot : la création du volume accepte l'option de chiffrement. La copie chiffrée reste utile pour conserver une sauvegarde elle-même chiffrée, ou pour changer de clé. Dans tous les cas, l'échange de volume demande une courte interruption.

Bonnes pratiques

- gp3 par défaut ; performance ajustée d'après les mesures.
- Chiffrement par défaut activé dans chaque région utilisée.
- Données sur un volume distinct du volume racine.
- Étiquettes sur les volumes, appliquées dès le lancement.
- Snapshots automatiques, avec une durée de conservation.
- Montage par UUID, avec `nofail`.
- Revue régulière des volumes détachés.

Erreur	Conséquence
Volume créé dans une autre zone que l'instance	Impossible de l'attacher.
Volume agrandi, système de fichiers non étendu	L'espace n'apparaît pas dans <code>df</code> .
<code>mkfs</code> sur un volume qui contenait des données	Données effacées.
Volumes laissés après suppression des instances	Facturation sans usage.
Données importantes sur le volume racine	Perdus à la suppression de l'instance.
Données uniques sur un disque local	Perdus à l'arrêt.
gp2 surdimensionné pour obtenir des IOPS	Surcoût : gp3 donne la performance sans la taille.
Croire qu'un volume répliqué est sauvegardé	Aucun retour possible après une suppression.

Volumes et images, partie 2

Snapshots et AMI personnalisées

Sauvegarder un volume, et figer une instance configurée pour la reproduire à l'identique.

- Le snapshot
- Sauvegardes incrémentales
- Créer, restaurer, copier
- Automatiser les sauvegardes
- L'AMI personnalisée
- Image ou script de démarrage

Définition : snapshot

Copie de l'état d'un volume EBS à un instant donné, conservée par AWS dans un stockage très durable, à partir de laquelle on peut créer de nouveaux volumes.


Propriété	Détail
Instantané	Il fige l'état du volume au moment de la demande, même si la copie prend du temps.
Incrémental	Seuls les blocs modifiés depuis le snapshot précédent sont stockés.
Régional	Conservé dans la région, hors de toute zone : il survit à la perte d'une zone.
Copiable	Vers une autre région ou un autre compte.
Sans arrêt	Il se prend sur un volume en service.
Chiffré	Si le volume l'est, automatiquement.

À quoi il sert

- **Sauvegarder** : revenir à un état antérieur après une erreur ou une corruption.
- **Déplacer** : recréer un volume dans une autre zone ou une autre région.
- **Dupliquer** : cloner un environnement pour un test.
- **Transformer** : changer de type, chiffrer.
- **Construire une AMI** : une image repose sur des snapshots.

Où sont-ils ? Dans S3, mais dans un espace géré par AWS : on ne les voit pas dans ses buckets, et on ne les manipule que par l'API d'EC2.

Schéma : des sauvegardes incrémentales



Chaque snapshot permet de restaurer le volume entier : il référence les blocs inchangés des précédents.

Supprimer un snapshot ne retire que les blocs qu'aucun autre n'utilise.

Coût. On paie les blocs réellement stockés, pas la taille du volume multipliée par le nombre de snapshots. Sept snapshots quotidiens d'un volume qui change peu coûtent à peine plus qu'un seul.

Suppression sans risque. On peut supprimer n'importe quel snapshot de la chaîne, même le premier : AWS conserve les blocs dont les suivants ont besoin.

\$ Prérequis : VOL défini ; remplacer user7

Créer un snapshot

```
SNAP=$(aws ec2 create-snapshot --volume-id $VOL \
  --description "user7 data avant migration" \
  --tag-specifications \
    'ResourceType=snapshot,Tags=[{Key=Owner,Value=user7}]' \
  --query SnapshotId --output text)
aws ec2 wait snapshot-completed --snapshot-ids $SNAP
```

Restaurer : un NOUVEAU volume, dans la zone voulue

```
aws ec2 create-volume --snapshot-id $SNAP \
  --availability-zone eu-west-3b --volume-type gp3
```

Copier vers une autre région

```
aws ec2 copy-snapshot --region eu-central-1 \
  --source-region eu-west-3 --source-snapshot-id $SNAP
```

Lister ses snapshots, du plus récent au plus ancien

```
aws ec2 describe-snapshots --owner-ids self \
  --output table --query '
    reverse(sort_by(Snapshots,&StartTime))[]
    [SnapshotId,VolumeSize,StartTime]'
```

La restauration


- On ne restaure pas « dans » le volume d'origine : on crée un nouveau volume, puis on l'échange.
- Le nouveau volume peut être plus grand, d'un autre type, dans une autre zone.
- Il est utilisable aussitôt ; les blocs sont rapatriés à la première lecture, d'où une lenteur initiale.

Définition : cohérence d'un snapshot

Un snapshot capture le disque à un instant, comme après une coupure de courant. Ce qui n'était encore qu'en mémoire n'y figure pas.

Pour une base de données installée sur une instance : utiliser l'outil de sauvegarde du moteur, ou suspendre les écritures le temps de lancer le snapshot. Pour plusieurs volumes liés, il existe des snapshots multi-volumes, pris au même instant.

Schéma : automatiser les sauvegardes



La sauvegarde ne dépend plus de la mémoire de quelqu'un : l'étiquette suffit.

Outil	Portée
Data Lifecycle Manager	Snapshots EBS et AMI, par étiquette. Simple et gratuit.
AWS Backup	Sauvegarde centralisée de nombreux services : EBS, RDS, DynamoDB, EFS, S3. Plans, coffres, rapports de conformité.

Définition : durée de conservation (rétention)

Règle qui fixe combien de sauvegardes, ou pendant combien de temps, on les garde avant suppression automatique.

Une sauvegarde non testée n'en est pas une. Prévoir, régulièrement, la restauration d'un snapshot sur une instance de test.

Options utiles des snapshots

Fonction	Ce qu'elle fait	Quand s'en servir
Copie entre régions	Duplique un snapshot dans une autre région.	Plan de reprise après la perte d'une région ; déploiement ailleurs.
Partage entre comptes	Autorise un autre compte à créer des volumes depuis le snapshot.	Passage de données d'un environnement à l'autre. Clé gérée par le client requise si chiffré.
Niveau archive	Stockage environ quatre fois moins cher ; restauration en 24 à 72 heures.	Conservation légale, snapshots que l'on ne relira sans doute jamais.
Fast Snapshot Restore	Volumes pleinement performants dès leur création.	Restaurations où la lenteur initiale est inacceptable. Payant.
Corbeille (Recycle Bin)	Conserve un temps les snapshots et AMI supprimés.	Filet de sécurité contre une suppression par erreur.
Verrou (Snapshot Lock)	Interdit la suppression pendant une durée fixée.	Protection contre un rançongiciel ou un acte malveillant.

Ne jamais rendre un snapshot public sans y avoir réfléchi : tout le contenu du disque devient lisible par n'importe quel compte AWS. Un réglage de compte, « Block public access for snapshots », l'interdit.

Nettoyage. Les snapshots survivent à leur volume et à leur instance. Sans règle de conservation, ils s'accumulent : c'est l'un des premiers postes à examiner sur une facture EC2 qui grossit.

Définition : AMI personnalisée

Image créée à partir d'une de vos instances. Elle regroupe un snapshot de chacun de ses volumes et les réglages nécessaires pour relancer des instances identiques.

Ce qu'elle contient

- Le système, ses mises à jour, les logiciels installés.
- L'application et sa configuration, si on les y a mises.
- La liste des volumes à créer : taille, type, chiffrement.
- L'architecture et les permissions de lancement.

Elle ne contient ni le type d'instance, ni le réseau, ni le rôle : ces choix se font au lancement, ou dans un modèle de lancement.


Pourquoi en créer

- **Démarrer vite** : une instance prête en une minute, au lieu de dix d'installation. Décisif pour l'Auto Scaling.
- **Reproduire** : toutes les instances sont rigoureusement identiques.
- **Ne pas dépendre d'Internet au démarrage** : plus de dépôt de paquets à joindre.
- **Revenir en arrière** : relancer avec l'image précédente.

Définition : image de référence (golden image)

AMI validée, tenue à jour et versionnée, à partir de laquelle sont lancées toutes les instances d'une application.

Schéma : figer une instance pour la reproduire



\$ Prérequis : INSTANCE est l'instance modèle ; remplacer user7

```
AMI_PERSO=$(aws ec2 create-image --instance-id $INSTANCE \
--name "user7-web-2026-10-05" \
--description "nginx + application, AL2023" \
--query ImageId --output text)
aws ec2 wait image-available --image-ids $AMI_PERSO
```

Redémarrage. Par défaut, `create-image` redémarre l'instance pour garantir un disque cohérent. L'option `--no-reboot` l'évite, au prix d'un risque d'incohérence. Créer l'image depuis une instance préparée pour cela, pas depuis un serveur en production.

Opération	Détail
Nommer	Un nom qui porte l'application et la date ou la version : <code>shop-web-2026-10-05</code> .
Copier	<code>copy-image</code> vers une autre région : l'identifiant y sera différent.
Partager	Avec d'autres comptes de l'organisation.
Déprécier	Marquer une image comme obsolète, sans la supprimer.
Supprimer	<code>deregister-image</code> , puis supprimer ses snapshots : ils ne partent pas avec elle.

Avant de créer l'image : retirer tout ce qui est propre à la machine ou sensible. Clés SSH, journaux, historique des commandes, secrets, fichiers temporaires.

\$ Lister, puis supprimer proprement une AMI

```
# Ses propres AMI, de la plus récente à la plus ancienne
aws ec2 describe-images --owners self --output table \
  --query 'reverse(sort_by(Images,&CreationDate))[]'
  [ImageId,Name,CreationDate] '

# Snapshots de l'image, à noter avant de la retirer
aws ec2 describe-images --image-ids $AMI_PERSO --query \
  'Images[0].BlockDeviceMappings[].Ebs.SnapshotId' --output text

# Retirer l'image, puis supprimer chaque snapshot noté
aws ec2 deregister-image --image-id $AMI_PERSO
aws ec2 delete-snapshot --snapshot-id snap-0abc123def4567890
```

Industrialiser. EC2 Image Builder, ou un outil comme Packer, fabrique les images selon une recette : image de base, composants à installer, tests, diffusion dans les régions. L'image n'est plus faite à la main.

Tout dans l'image, ou tout au démarrage ?

	Dans l'AMI (image préparée)	Dans le user data (script de démarrage)
Temps de démarrage	Court : tout est déjà installé.	Long : tout s'installe à chaque lancement.
Reproductibilité	Totale.	Dépend des dépôts joints ce jour-là.
Dépendance au réseau	Aucune au démarrage.	Sortie vers Internet indispensable.
Changer une configuration	Reconstruire une image.	Modifier le script.
Correctifs de sécurité	Reconstruire régulièrement.	Appliqués à chaque lancement.
Nombre d'images à gérer	Une par version.	L'image de base suffit.

Le compromis habituel. Dans l'image : le système à jour, les paquets, l'application. Dans le user data : ce qui varie d'un environnement à l'autre, c'est-à-dire quelques lignes de configuration et le démarrage du service.

Règle de décision. Tout ce qui est long ou identique partout va dans l'image. Tout ce qui est court et dépend de l'environnement va dans le script.

Erreur	Conséquence	Correction
Aucune règle de conservation	Des centaines de snapshots, facturés indéfiniment.	Data Lifecycle Manager ou AWS Backup.
AMI retirée, snapshots conservés	Stockage payé pour rien.	Supprimer les snapshots après <code>deregister-image</code> .
Snapshots dans la seule région de production	Rien à restaurer si la région est indisponible.	Copie automatique vers une seconde région.
Snapshot d'une base en pleine écriture	Restauration incohérente.	Sauvegarde du moteur, ou écritures suspendues.
Secrets ou clés laissés dans une AMI	Fuite à chaque partage de l'image.	Nettoyer avant <code>create-image</code> .
AMI jamais reconstruite	Instances lancées avec des failles connues.	Reconstruction régulière et automatisée.
Snapshot ou AMI rendus publics	Contenu du disque exposé à tous.	Bloquer l'accès public au niveau du compte.
Restauration jamais essayée	Découverte du problème le jour du sinistre.	Test de restauration périodique.

Volumes et images, partie 3

Les modèles de lancement

Écrire une fois la recette d'une instance, pour que personne, ni humain ni automate, n'ait à la ressaisir.

- Définition
- Contenu d'un modèle
- Les versions
- Créer et utiliser un modèle
- Qui s'en sert
- Synthèse : volumes et images

Définition : modèle de lancement (launch template)

Objet qui enregistre les paramètres de lancement d'une instance : AMI, type, réseau, stockage, rôle, user data. On lance ensuite une instance en ne citant que le modèle.


Paramètre	Dans le modèle ?
AMI	Oui
Type d'instance	Oui
Security groups	Oui
Rôle d'instance	Oui
Volumes : taille, type, chiffrement	Oui
User data	Oui
Options de métadonnées (IMDSv2)	Oui
Étiquettes des instances et des volumes	Oui
Paire de clés, option Spot	Oui, facultatifs
Sous-réseau	Possible, mais on le laisse en général à l'Auto Scaling

Ce que l'on y gagne

- **Une seule définition** : la même pour la console, la CLI et les automates.
- **Plus d'oubli** : chiffrement, IMDSv2, rôle et étiquettes sont dans le modèle.
- **Un historique** : chaque changement crée une version.
- **Un prérequis** : l'Auto Scaling lance ses instances à partir d'un modèle.

Tous les champs sont facultatifs. Ce qui n'est pas dans le modèle se précise au lancement, et ce qui y figure peut être remplacé ponctuellement.

Launch configuration. C'est l'ancien mécanisme, sans versions et désormais abandonné : on ne crée plus que des modèles de lancement.



Lecture. Le modèle compte trois versions. `$Latest` désigne toujours la dernière créée ; `$Default` désigne celle que l'on a choisie comme référence. Ici, la version 3 existe mais n'est pas encore la version par défaut.

Déployer et revenir en arrière. Nouvelle image : nouvelle version du modèle. On la teste, puis on la désigne par défaut. En cas de problème, on redésigne la précédente : aucune version n'est jamais écrasée.

\$ Prérequis : AMI_ID, SG_APP, PRIV_A définis ; instance profile user7-role-ec2 et fichier userdata.sh existants ; remplacer user7

1. Les paramètres du modèle, dans un fichier ; le user data doit être encodé en base64

```
cat > lt.json <<EOF
```

```
{ "ImageId": "$AMI_ID", "InstanceType": "t3.micro",
  "SecurityGroupIds": ["$SG_APP"],
  "IamInstanceProfile": { "Name": "user7-role-ec2" },
  "MetadataOptions": { "HttpTokens": "required", "HttpEndpoint": "enabled" },
  "BlockDeviceMappings": [ { "DeviceName": "/dev/xvda",
    "Ebs": { "VolumeSize": 8, "VolumeType": "gp3", "Encrypted": true } } ],
  "UserData": "$(base64 < userdata.sh | tr -d '\n')",
  "TagSpecifications": [ { "ResourceType": "instance",
    "Tags": [ { "Key": "Name", "Value": "user7-web" }, { "Key": "Owner", "Value": "user7" } ] } ] }
```

```
EOF
```

2. Créer le modèle (version 1)

```
aws ec2 create-launch-template --launch-template-name user7-lt-web --launch-template-data file://lt.json
```

3. Lancer une instance : seul le sous-réseau reste à préciser

```
aws ec2 run-instances --launch-template LaunchTemplateName=user7-lt-web,Version='$Default' --subnet-id $PRIV_A
```

4. Nouvelle version : on part de la version 1 et on ne change que le type

```
aws ec2 create-launch-template-version --launch-template-name user7-lt-web --source-version 1 \
  --launch-template-data '{"InstanceType":"t3.small"}'
```

5. La désigner comme version par défaut, puis lister les versions

```
aws ec2 modify-launch-template --launch-template-name user7-lt-web --default-version 2
```

```
aws ec2 describe-launch-template-versions --launch-template-name user7-lt-web \
  --query 'LaunchTemplateVersions[].[VersionNumber,DefaultVersion,LaunchTemplateData.InstanceType]' --output table
```

Qui utilise les modèles de lancement

Utilisateur	Usage
Vous, à la main	« Launch instance from template » dans la console ; <code>run-instances --launch-template</code> .
Auto Scaling group	Lance et remplace des instances selon la charge, d'après une version du modèle.
EC2 Fleet, Spot Fleet	Obtiennent une capacité donnée en combinant types et modes d'achat.
Groupe de nœuds EKS, AWS Batch	Créent leurs machines à partir d'un modèle.
CloudFormation, Terraform	Décrivent le modèle en code, avec le reste de l'infrastructure.

Bonnes pratiques

- Un modèle par rôle applicatif : `shop-lt-web`, `shop-lt-worker`.
- Dans le modèle, tout ce qui relève de la sécurité : chiffrement, IMDSv2, rôle, security groups.
- Pas de sous-réseau dans le modèle destiné à l'Auto Scaling : c'est le groupe qui répartit sur les zones.
- Une description sur chaque version : ce qui a changé.
- Faire pointer l'Auto Scaling sur une version précise ou sur `$Default`, plutôt que sur `$Latest` : une version créée par erreur ne part pas aussitôt en production.

Lien avec le chapitre « Élasticité ». Image, modèle de lancement et load balancer sont les ingrédients de l'Auto Scaling : l'image dit quoi lancer, le modèle comment, le load balancer où envoyer le trafic.

Ce qu'il faut retenir

- Un volume EBS est un disque en réseau, persistant, lié à une zone.
- gp3 par défaut : taille, IOPS et débit se règlent séparément, et à chaud.
- Aggrandir un volume demande ensuite d'étendre le système de fichiers ; on ne réduit jamais.
- Le chiffrement est gratuit et transparent : l'activer par défaut.
- Un snapshot est une sauvegarde incrémentale, régionale, à partir de laquelle on crée de nouveaux volumes.
- Une AMI personnalisée fige une instance configurée ; elle repose sur des snapshots.
- Un modèle de lancement enregistre la recette d'une instance, avec des versions.

1. Peut-on attacher un volume de la zone a à une instance de la zone b ?

2. Quelle est la performance de base d'un volume gp3 ?

3. Après modify-volume, que reste-t-il à faire ?

4. Que devient un disque local à l'arrêt de l'instance ?

5. Pourquoi dit-on qu'un snapshot est incrémental ?

6. Que faut-il supprimer après deregister-image ?

7. Que désignent \$Latest et \$Default ?

Cliquer sur une question pour afficher la réponse.

Répartition de charge, partie 1


L'Application Load Balancer

Le point d'entrée unique de l'application : il reçoit les requêtes, les répartit entre les serveurs en bonne santé, et écarte les autres.

- Pourquoi un load balancer
- Les types de load balancers
- Listeners et règles
- Target groups
- Health checks
- Mise en œuvre et diagnostic

Schéma : ce que change un load balancer

Sans load balancer




Une panne ou une mise à jour : service arrêté.

Une seule zone de disponibilité.

Pour grossir : une machine plus puissante, avec coupure.

Avec load balancer



La cible en panne est écartée ; les autres absorbent.

Définition : répartiteur de charge (load balancer)

Composant qui reçoit les connexions des clients et les distribue entre plusieurs serveurs, en n'en retenant que ceux qui fonctionnent.

Trois services rendus

Disponibilité : une cible en panne n'interrompt pas le service. **Montée en charge** : on ajoute des cibles sans que les clients le sachent. **Point d'entrée stable** : un seul nom, un seul certificat, pendant que les serveurs se renouvellent derrière.

Définition : Elastic Load Balancing (ELB)
Service managé de répartition de charge d'AWS. Il fournit des load balancers redondants, qui s'ajustent d'eux-mêmes au trafic.

Type	Couche	Protocoles	Usage
Application Load Balancer (ALB)	7, application	HTTP, HTTPS, gRPC, WebSocket	Sites et API web : routage selon l'URL, l'hôte, les en-têtes.
Network Load Balancer (NLB)	4, transport	TCP, UDP, TLS	Très hautes performances, protocoles non HTTP, adresses IP fixes.
Gateway Load Balancer (GWLB)	3, réseau	Tout trafic IP	Insérer des équipements de sécurité tiers sur le chemin du trafic.
Classic Load Balancer	4 et 7	HTTP, TCP	Génération précédente : à ne plus choisir.

Définition : couches 4 et 7
Niveaux du modèle réseau. En couche 4, le load balancer ne voit que des connexions : adresses et ports. En couche 7, il lit la requête HTTP : méthode, chemin, en-têtes.

Choix par défaut. Pour une application web ou une API HTTP : l'Application Load Balancer. Le Network Load Balancer répond à des besoins précis, vus dans la partie suivante.

L'Application Load Balancer


Caractéristique	Détail
Managé	Rien à installer ni à mettre à jour ; capacité ajustée automatiquement.
Multi-zones	Présent dans au moins deux zones : il exige deux sous-réseaux.
Un nom DNS	On le joint par son nom ; ses adresses IP changent.
Public ou interne	« Internet-facing » dans des sous-réseaux publics, ou « internal » dans des sous-réseaux privés.
Security group	Il porte le sien : c'est <code>sg-alb</code> dans le chaînage.
Terminaison TLS	Il porte le certificat et déchiffre HTTPS.

Ce qu'il sait faire de plus qu'un simple répartiteur

- Router selon le chemin ou le nom d'hôte : plusieurs applications derrière un seul load balancer.
- Rediriger HTTP vers HTTPS.
- Répondre lui-même : page de maintenance, code d'erreur.
- Authentifier les utilisateurs avant de transmettre (OIDC, Cognito).
- Cibler des instances, des adresses IP, des conteneurs, des fonctions Lambda.
- Répartir entre deux versions selon un poids, pour un déploiement progressif.

Protection. AWS WAF s'attache à un ALB pour filtrer les requêtes malveillantes ; AWS Shield le protège d'office contre les attaques par saturation les plus courantes.

Schéma : les composants d'un ALB

**Définition : listener**

Processus du load balancer qui écoute sur un protocole et un port, par exemple HTTPS sur 443, et applique ses règles à chaque requête reçue.

Définition : règle

Couple formé de conditions (chemin, hôte, en-tête) et d'une action (transmettre, rediriger, répondre). Chaque listener a une règle par défaut.

Définition : target group

Ensemble de cibles vers lesquelles le load balancer transmet, avec leur protocole, leur port et leur contrôle de santé.

Condition	Exemple
Chemin	/api/* , /images/*
Nom d'hôte	admin.utopios.example
En-tête HTTP	X-Version: beta
Méthode	POST
Paramètre de requête	?lang=fr
Adresse IP source	203.0.113.0/24

Action	Effet
forward	Transmettre à un target group, ou à plusieurs selon des poids.
redirect	Renvoyer le client vers une autre URL : HTTP vers HTTPS.
fixed-response	Répondre directement : code et corps fixés.
authenticate	Exiger une connexion avant de poursuivre.


Évaluation

- Les règles sont examinées par **ordre de priorité**, du plus petit numéro au plus grand.
- La première dont toutes les conditions sont vraies s'applique ; les suivantes sont ignorées.
- Si aucune ne correspond, la **règle par défaut** s'applique.

Deux listeners courants. Le port 80, dont la règle par défaut redirige vers HTTPS ; le port 443, qui porte le certificat et les règles de routage.

Ordre des règles. Une règle large placée avant une règle précise la masque : `/*` en priorité 1 capte tout, et `/api/*` en priorité 2 n'est jamais atteinte. Les règles les plus précises reçoivent les plus petits numéros.

Schéma : le routage par règles



Lecture. Un seul load balancer, un seul nom et un seul certificat servent trois applications. Chaque requête est orientée selon son chemin ou son nom d'hôte ; ce qui ne correspond à aucune règle va au site web. C'est ce qui permet de découper une application en services sans multiplier les points d'entrée.

Type de cible	Usage
instance	Des instances EC2, désignées par leur identifiant. Le cas de cette formation.
ip	Des adresses IP : tâches Fargate, pods Kubernetes, serveurs hors d'AWS reliés au VPC.
lambda	Une fonction Lambda, appelée à chaque requête.

Ce que définit un target group

- Le protocole et le port de transmission : HTTP 8080, par exemple.
- Le contrôle de santé appliqué à chaque cible.
- L'algorithme de répartition.
- Des réglages : délai de désinscription, sessions persistantes.

Algorithme	Principe
Round robin (par défaut)	Chaque cible à tour de rôle.
Least outstanding requests	La cible qui a le moins de requêtes en cours : meilleur quand les requêtes ont des durées inégales.
Weighted random	Tirage pondéré, avec détection des cibles anormalement lentes.

Inscription des cibles. À la main, pour un essai. En pratique, c'est l'Auto Scaling group, le service ECS ou le contrôleur Kubernetes qui inscrit et désinscrit les cibles au fil de leur vie.

Un target group, plusieurs ports. Une même instance peut être inscrite plusieurs fois avec des ports différents : c'est ainsi que plusieurs conteneurs d'une même machine reçoivent du trafic.

Définition : **contrôle de santé (health check)**


Requête envoyée à intervalles réguliers par le load balancer à chaque cible. Selon les réponses, la cible est déclarée saine et reçoit du trafic, ou défaillante et n'en reçoit plus.

Paramètre	Valeur par défaut	Rôle
Protocole et port	Ceux du target group	Où envoyer la sonde.
Chemin	/	URL interrogée.
Intervalle	30 s	Délai entre deux sondes.
Délai d'attente	5 s	Au-delà, la sonde est un échec.
Seuil de bonne santé	5 réussites	Pour passer à « healthy ».
Seuil de défaillance	2 échecs	Pour passer à « unhealthy ».
Codes de succès	200	Réponses considérées comme saines.

Concevoir un bon contrôle

- Un chemin dédié, `/health`, qui répond vite et sans authentification.
- Il vérifie que l'application est capable de servir, pas seulement que le serveur web tourne.
- Il ne dépend pas d'un service externe qui, en tombant, ferait écarter toutes les cibles à la fois.


Durées à connaître. Avec les valeurs par défaut, une cible neuve met 2 minutes 30 à devenir saine (5 × 30 s) et une cible en panne une minute à être écartée. On raccourcit souvent : intervalle de 10 s, seuil de bonne santé de 2 ou 3.



Lecture. La troisième cible ne répond plus : après deux échecs, elle cesse de recevoir du trafic. Le load balancer continue pourtant de la sonder ; dès qu'elle répond de nouveau le nombre de fois requis, elle est réintégrée sans intervention.

Toutes les cibles défectueuses. Si aucune cible n'est saine, l'ALB envoie tout de même le trafic à toutes, plutôt que de tout refuser. Un contrôle de santé mal réglé ne coupe donc pas forcément le service, mais il masque les vraies pannes.

Schéma : un ALB réparti sur deux zones



Lecture. Le load balancer place un nœud dans chaque sous-réseau public choisi. Les instances restent dans les sous-réseaux privés, sans adresse publique. Chaque nœud réparti sur les cibles de toutes les zones, et pas seulement de la sienne : c'est la répartition entre zones, toujours active sur un ALB.

Filtrage. On retrouve le chaînage du chapitre « Filtrage et accès privés » : `sg-alb` accepte Internet sur 443, `sg-app` n'accepte que `sg-alb` sur le port de l'application. Le contrôle de santé emprunte ce même chemin.

Réglage	Effet	Quand y toucher
Délai de désinscription	Temps laissé aux requêtes en cours avant de retirer une cible. 300 s par défaut.	Le réduire (30 s) si les requêtes sont courtes : les déploiements vont plus vite.
Sessions persistantes (stickiness)	Un client retourne toujours vers la même cible, grâce à un cookie.	Seulement si l'application garde l'état en mémoire. Mieux : sortir l'état dans un cache partagé.
Démarrage progressif (slow start)	Une cible neuve reçoit le trafic par paliers.	Application qui a besoin de se réchauffer.
Délai d'inactivité	Fermeture des connexions sans échange. 60 s par défaut.	Requêtes longues, connexions WebSocket.
Journaux d'accès	Une ligne par requête, déposée dans S3.	À activer : diagnostic, audit, analyse du trafic.
Protection contre la suppression	Empêche de supprimer le load balancer par erreur.	En production.

Définition : X-Forwarded-For

En-tête ajouté par le load balancer, qui contient l'adresse IP réelle du client. Sans lui, l'application ne verrait que l'adresse du load balancer.

Côté application. Lire X-Forwarded-For pour l'adresse du client et X-Forwarded-Proto pour savoir si la requête d'origine était en HTTPS. Les serveurs web et les frameworks ont une option pour cela.

Ligne de commande : créer un ALB complet

\$ Prérequis : VPC_ID, PUB_A, PUB_B, SG_ALB définis ; deux instances (INST_1, INST_2) qui répondent sur le port 80 ; remplacer user7

1. Le target group : où transmettre, et comment vérifier la santé

```
TG=$(aws elbv2 create-target-group --name user7-tg-web --protocol HTTP --port 80 --vpc-id $VPC_ID \
--target-type instance --health-check-path /health --health-check-interval-seconds 10 \
--healthy-threshold-count 2 --unhealthy-threshold-count 2 \
--query 'TargetGroups[0].TargetGroupArn' --output text)
```

2. Y inscrire les instances

```
aws elbv2 register-targets --target-group-arn $TG --targets Id=$INST_1 Id=$INST_2
```

3. Le load balancer : public, dans les deux sous-réseaux publics

```
ALB=$(aws elbv2 create-load-balancer --name user7-alb --type application --scheme internet-facing \
--subnets $PUB_A $PUB_B --security-groups $SG_ALB \
--query 'LoadBalancers[0].LoadBalancerArn' --output text)
aws elbv2 wait load-balancer-available --load-balancer-arns $ALB
```

4. Le listener HTTP : règle par défaut, transmettre au target group

```
aws elbv2 create-listener --load-balancer-arn $ALB --protocol HTTP --port 80 \
--default-actions Type=forward,TargetGroupArn=$TG
```

5. État des cibles, puis test par le nom DNS du load balancer

```
aws elbv2 describe-target-health --target-group-arn $TG --output table \
--query 'TargetHealthDescriptions[].[Target.Id,TargetHealth.State,TargetHealth.Reason]'
```

DNS=\$(aws elbv2 describe-load-balancers --load-balancer-arns \$ALB --query 'LoadBalancers[0].DNSName' --output text)

```
curl -s http://$DNS/
```

À ne pas oublier. `sg-app` doit accepter le port 80 depuis `sg-alb`, sans quoi les cibles restent « unhealthy ». Le service s'appelle `e1bv2` dans la CLI ; `e1b` désigne l'ancien Classic Load Balancer.

État d'une cible	Signification
initial	Inscrite, contrôles en cours.
healthy	Saine : elle reçoit du trafic.
unhealthy	Contrôles en échec. La colonne « Reason » dit pourquoi : délai dépassé, mauvais code de réponse.
draining	En cours de désinscription : elle termine ses requêtes.
unused	Aucun listener ne transmet à ce target group, ou la zone de la cible n'est pas activée sur le load balancer.

Code	Signification	Cause fréquente
502	Réponse invalide de la cible.	Application qui ferme la connexion, plante ou répond n'importe quoi.
503	Aucune cible disponible.	Target group vide, ou cibles toutes désinscrites.
504	La cible n'a pas répondu à temps.	Security group qui bloque, application trop lente.
4xx	Requête refusée.	Vient de l'application ou d'une règle.

Qui a produit l'erreur ? Les métriques CloudWatch distinguent les codes émis par le load balancer (`HTTPCode_ELB_5XX`) de ceux renvoyés par les cibles (`HTTPCode_Target_5XX`). Les journaux d'accès donnent le détail, requête par requête.

Démarche. Cible « unhealthy » : tester le chemin de santé depuis l'instance elle-même, puis vérifier le security group, puis le port du target group. C'est la méthode du chapitre « Dépannage réseau », appliquée au flux du load balancer vers la cible.

Le coût d'un ALB

Composante	Tarif indicatif
Heures d'existence	0,0225 \$ par heure, soit environ 16 \$ par mois.
Unités de capacité (LCU)	0,008 \$ par LCU et par heure.
Adresses IPv4 publiques	Une par zone : 0,005 \$ par heure chacune.

Définition : LCU (unité de capacité)

Unité de facturation qui mesure l'activité d'un load balancer selon quatre dimensions : nouvelles connexions, connexions actives, volume traité, règles évaluées. Seule la plus élevée est facturée.

Situation mensuelle	Ordre de grandeur
ALB sans trafic, deux zones	24 \$
Petit site, quelques requêtes par seconde	30 \$
Dix applications, un ALB chacune	240 \$ avant tout trafic
Les mêmes derrière un seul ALB, par règles	24 \$ avant tout trafic

Mutualiser. Les règles par hôte et par chemin permettent de servir de nombreuses applications avec un seul load balancer : c'est le premier levier d'économie.

Un ALB oublié coûte tant qu'il existe, même sans cible. À supprimer en fin d'exercice, avec ses target groups.

Erreur	Symptôme	Correction
sg-app n'autorise pas sg-alb	Cibles « unhealthy », erreurs 504.	Règle entrante depuis le security group du load balancer.
Port du target group différent du port d'écoute	Cibles « unhealthy ».	Aligner target group, application et security group.
Chemin de santé inexistant ou protégé	Cibles « unhealthy » avec un code 404 ou 401.	Chemin dédié, public, ou élargir les codes acceptés.
ALB public dans des sous-réseaux privés	Injoignable depuis Internet.	Sous-réseaux publics pour un ALB « internet-facing ».
Un seul sous-réseau	Création refusée.	Deux sous-réseaux dans deux zones.
Zone des cibles non activée sur l'ALB	Cibles « unused ».	Ajouter un sous-réseau de cette zone au load balancer.
Adresse IP du load balancer notée en dur	Panne quand elle change.	Toujours le nom DNS, ou un alias Route 53.
Règle large avant une règle précise	Routage inattendu.	Revoir les priorités.
Instances publiques derrière l'ALB	Le load balancer peut être contourné.	Instances privées, joignables du seul sg-alb.

Répartition de charge, partie 2

Le Network Load Balancer

Le répartiteur de la couche transport : plus simple, plus rapide, et doté d'adresses fixes.

- Définition et caractéristiques
- Fonctionnement
- ALB ou NLB
- Quand choisir le NLB
- Combinaisons utiles
- Erreurs fréquentes

Définition : Network Load Balancer (NLB)

Load balancer de couche 4 : il répartit des connexions TCP, UDP ou TLS sans en interpréter le contenu, avec une latence très faible et une adresse IP fixe par zone.


Caractéristique	Détail
Protocoles	TCP, UDP, TLS. N'importe quel protocole applicatif au-dessus.
Adresses	Une adresse fixe par zone ; on peut y associer ses propres Elastic IP.
Performance	Des millions de requêtes par seconde, latence ajoutée minime, absorbe les pointes brutales.
Adresse du client	Conservée : la cible voit l'adresse réelle du client.
Routage	Par connexion : toute la connexion va à la même cible.
Contrôles de santé	TCP, HTTP ou HTTPS.
Security group	Facultatif, à associer dès la création.

Ce qu'il ne fait pas

- Lire l'URL, l'hôte ou les en-têtes : aucun routage par chemin.
 - Rediriger, répondre lui-même, authentifier.
 - S'associer à AWS WAF.
- Pour lui, HTTP n'est qu'un flux d'octets parmi d'autres.

Répartition entre zones. Désactivée par défaut sur un NLB : chaque adresse ne sert que les cibles de sa zone. À activer si les cibles sont réparties inégalement.

Schéma : le fonctionnement d'un NLB



Lecture. Les clients se connectent à des adresses qui ne changent jamais. Le NLB choisit une cible pour chaque nouvelle connexion et lui transmet les paquets tels quels ; la cible voit l'adresse du client comme s'il s'adressait à elle directement.

Conséquence sur le filtrage. Puisque la cible voit l'adresse du client, son security group doit autoriser les **clients** eux-mêmes, ou le security group du NLB s'il en porte un. Raisonner comme avec un ALB conduit à des cibles injoignables.

	Application Load Balancer	Network Load Balancer
Couche	7 : requêtes HTTP.	4 : connexions TCP et UDP.
Routage	Par chemin, hôte, en-tête, méthode.	Par port.
Adresses IP	Variables : on utilise le nom DNS.	Fixes, une par zone ; Elastic IP possibles.
Adresse du client	Dans l'en-tête X-Forwarded-For.	Conservée dans les paquets.
Terminaison TLS	Oui.	Oui, ou transmission chiffrée de bout en bout.
Redirections, réponses fixes, authentification	Oui.	Non.
AWS WAF	Oui.	Non.
Cibles	Instances, adresses IP, Lambda.	Instances, adresses IP, un ALB.
Performance	Élevée.	Extrême, latence la plus faible.
PrivateLink	Non.	Oui : exposer un service à d'autres VPC.

Question à se poser. Le trafic est-il du HTTP, et ai-je besoin de regarder dedans ? Si oui, ALB. Si le protocole n'est pas HTTP, ou si des adresses fixes ou une latence minimale sont exigées, NLB.

Quand choisir le Network Load Balancer

Besoin	Pourquoi le NLB
Protocole autre que HTTP : base de données, messagerie MQTT, jeu en ligne, DNS, SFTP	L'ALB ne comprend que HTTP.
Trafic UDP	Seul le NLB le prend en charge.
Adresses IP fixes à communiquer à un partenaire	Une Elastic IP par zone.
Très forte charge, pointes soudaines	Il absorbe sans préchauffage.
Latence minimale	Aucun traitement de la requête.
Chiffrement de bout en bout jusqu'à l'application	Il transmet le flux TLS sans le déchiffrer.
Exposer un service par PrivateLink	PrivateLink s'appuie sur un NLB.

Combinaisons utiles

- **NLB devant un ALB** : le NLB apporte les adresses fixes ou PrivateLink, l'ALB le routage HTTP. Le target group du NLB est alors de type « alb ».
- **NLB interne** : répartir entre les nœuds d'une base ou d'un cache que l'on exploite soi-même.

Coût. Proche de celui d'un ALB : environ 0,0225 \$ par heure, plus des unités de capacité propres au NLB.

Dans cette formation, l'application est un site web : on utilise un ALB. Le NLB est présenté pour savoir le reconnaître et le choisir à bon escient.

Erreur	Symptôme	Correction
Security group des cibles réglé comme pour un ALB	Cibles saines ou non, clients sans réponse.	Autoriser les adresses des clients, ou le security group du NLB.
Choisir un NLB pour une application web courante	Pas de routage par chemin, pas de redirection, pas de WAF.	ALB.
Cibles dans une zone où le NLB n'a pas d'adresse	Cibles inutilisées.	Activer la zone, ou la répartition entre zones.
Répartition entre zones désactivée, cibles inégales	Une zone surchargée, l'autre au repos.	Activer la répartition entre zones.
Contrôle de santé TCP seul	Cible déclarée saine alors que l'application est bloquée.	Contrôle HTTP sur un chemin de santé, quand c'est possible.
Vouloir ajouter un security group après coup	Refusé.	Il se décide à la création du NLB.
Application qui ne voit pas l'adresse du client	Cibles de type IP sans conservation de l'adresse.	Activer la conservation, ou le « proxy protocol ».

Repère. Les deux load balancers partagent les mêmes notions : listeners, target groups, contrôles de santé. Passer de l'un à l'autre ne change pas la façon de penser, seulement le niveau auquel le trafic est examiné.

Répartition de charge, partie 3

HTTPS et certificats ACM

Chiffrer les échanges entre les clients et l'application, avec un certificat gratuit qui se renouvelle tout seul.

- TLS et certificats : rappels
- La terminaison TLS sur le load balancer
- AWS Certificate Manager
- Validation par le DNS
- Listener HTTPS et redirection
- Nom de domaine et erreurs fréquentes

Définition : TLS

Protocole qui chiffre une connexion et prouve l'identité du serveur. HTTPS est HTTP transporté dans TLS. Son ancêtre s'appelait SSL, d'où l'usage persistant de ce mot.

Définition : certificat

Document numérique qui associe un nom de domaine à une clé publique, signé par une autorité de certification reconnue par les navigateurs.

Définition : autorité de certification

Organisme qui vérifie qu'un demandeur contrôle bien un domaine, puis signe son certificat. Les navigateurs font confiance à une liste d'autorités.

Ce que HTTPS garantit


- **Confidentialité** : personne sur le trajet ne lit les échanges.
- **Intégrité** : personne ne les modifie.
- **Authenticité** : le client parle bien au site attendu.

Ce qu'il faut pour l'offrir

- Un nom de domaine que l'on contrôle.
- Un certificat valide pour ce nom, et sa clé privée.
- Un point de terminaison qui présente le certificat : ici, le load balancer.

Aujourd'hui, HTTPS n'est plus une option. Les navigateurs signalent comme « non sécurisé » tout site en HTTP, et de nombreuses fonctions du web l'exigent.

Schéma : la terminaison TLS sur le load balancer



Définition : terminaison TLS

Fait de déchiffrer la connexion HTTPS sur un composant intermédiaire, ici le load balancer, qui transmet ensuite la requête aux serveurs.

Pourquoi sur le load balancer

Un seul certificat à gérer, au lieu d'un par serveur. Les instances n'ont ni clé privée à protéger ni chiffrement à calculer. Et le load balancer, qui voit la requête en clair, peut la router selon son chemin.

Définition : AWS Certificate Manager (ACM)

Service qui délivre, stocke et renouvelle des certificats TLS, et les met à disposition des services AWS qui terminent des connexions HTTPS.


Caractéristique	Détail
Gratuit	Les certificats publics utilisés avec un service intégré ne coûtent rien.
Renouvellement automatique	ACM renouvelle avant l'échéance, sans intervention, si la validation DNS reste en place.
Clé privée protégée	Elle reste dans ACM : on ne la manipule pas, on ne peut pas la perdre.
Régional	Un certificat sert dans la région où il a été demandé.
Noms multiples	Un certificat peut couvrir plusieurs noms, et des jokers : *.utopios.example .

Service	Région du certificat
Load balancer (ALB, NLB)	Celle du load balancer.
API Gateway régionale	Celle de l'API.
CloudFront	Toujours us-east-1.

Limite. Un certificat public ACM est fait pour les services AWS intégrés. Il ne s'installe pas simplement sur une instance EC2 : pour terminer TLS sur un serveur, on utilise un autre certificat, par exemple Let's Encrypt.

Certificat joker. *.utopios.example couvre shop.utopios.example et api.utopios.example , mais ni utopios.example ni a.b.utopios.example .

Schéma : la validation par le DNS



Le CNAME prouve que vous contrôlez le domaine. Le laisser en place garantit le renouvellement automatique.

Méthode	Principe	Renouvellement
DNS	Créer un enregistrement CNAME indiqué par ACM.	Automatique.
E-mail	Cliquer sur un lien reçu aux adresses du domaine.	Demande un nouveau clic.

Toujours la validation DNS. Elle s'automatise, ne dépend de personne, et rend le renouvellement transparent. Si la zone est hébergée dans Route 53, la console propose de créer l'enregistrement en un clic.

\$ Prérequis : un domaine que vous contrôlez ; zone hébergée Route 53 (ZONE_ID)

1. Demander le certificat, validation par DNS

```
CERT=$(aws acm request-certificate \  
  --domain-name shop.utopios.example \  
  --validation-method DNS \  
  --query CertificateArn --output text)
```

2. L'enregistrement CNAME demandé par ACM

```
aws acm describe-certificate --certificate-arn $CERT \  
  --query 'Certificate.DomainValidationOptions[0].ResourceRecord'
```

3. Créer ce CNAME dans la zone DNS

(console ACM : bouton « Create records in Route 53 »)

4. Attendre l'émission, puis vérifier l'état

```
aws acm wait certificate-validated --certificate-arn $CERT  
aws acm describe-certificate --certificate-arn $CERT \  
  --query 'Certificate.[Status,NotAfter,InUseBy]'
```

État	Signification
PENDING_VALIDATION	ACM attend la preuve : le CNAME n'existe pas encore, ou n'est pas encore visible.
ISSUED	Certificat émis, utilisable.
FAILED, VALIDATION_TIMED_OUT	Preuve non fournie dans les 72 heures : refaire la demande.

Délai. Avec Route 53, l'émission prend en général quelques minutes après la création du CNAME.

Ne pas supprimer le CNAME une fois le certificat émis : il sert à chaque renouvellement. Sans lui, le certificat expire et le site affiche une alerte de sécurité.

En formation, sans domaine à soi, on ne peut pas obtenir de certificat public : l'étape HTTPS se fait alors en démonstration par le formateur.

\$ Prérequis : ALB, TG et CERT définis ; sg-alb autorise les ports 80 et 443 depuis Internet

1. Listener HTTPS : le certificat, une politique TLS, et la transmission au target group

```
aws elbv2 create-listener --load-balancer-arn $ALB --protocol HTTPS --port 443 \
  --certificates CertificateArn=$CERT \
  --ssl-policy ELBSecurityPolicy-TLS13-1-2-2021-06 \
  --default-actions Type=forward,TargetGroupArn=$TG
```

2. Listener HTTP : sa seule action est de rediriger vers HTTPS (remplace le listener 80 créé plus tôt)

```
LISTENER_80=$(aws elbv2 describe-listeners --load-balancer-arn $ALB \
  --query 'Listeners[?Port==`80`].ListenerArn' --output text)
aws elbv2 modify-listener --listener-arn $LISTENER_80 \
  --default-actions 'Type=redirect,RedirectConfig={Protocol=HTTPS,Port=443,StatusCode=HTTP_301}'
```

3. Vérifier : HTTP redirige, HTTPS répond

```
curl -sI http://shop.utopios.example/ | head -3
curl -sI https://shop.utopios.example/ | head -1
```

Définition : politique de sécurité TLS

Réglage d'un listener HTTPS qui fixe les versions de TLS et les algorithmes de chiffrement acceptés. Une politique récente refuse les versions anciennes et vulnérables.

Choisir la politique. Prendre une politique qui n'accepte que TLS 1.2 et 1.3, comme celle de l'exemple. Les politiques plus anciennes n'existent que pour des clients très vieux, et font échouer les audits de sécurité.

Définition : SNI (Server Name Indication)

Extension de TLS par laquelle le client annonce, dès le début de la connexion, le nom de domaine qu'il veut joindre. Le serveur choisit alors le certificat correspondant.

Sur un load balancer

- Un listener HTTPS a un certificat par défaut, et peut en porter d'autres.
- Grâce au SNI, il présente à chaque client le certificat du nom demandé.
- Combiné aux règles par nom d'hôte, un seul load balancer sert plusieurs sites, chacun avec son certificat.

\$ Ajouter un certificat à un listener

```
aws elbv2 add-listener-certificates \  
  --listener-arn $LISTENER_443 \  
  --certificates CertificateArn=$CERT_ADMIN
```

Besoin**Solution**

Quelques sous-domaines connus

Un certificat avec plusieurs noms.

Sous-domaines nombreux ou créés à la volée


Un certificat joker.

Domaines sans rapport entre eux

Un certificat par domaine, ajoutés au listener.

Alerte de sécurité dans le navigateur ? Le nom tapé ne figure pas dans le certificat présenté. Vérifier le nom, puis les certificats du listener.

Schéma : un nom de domaine devant le load balancer



Un alias suit de lui-même les adresses du load balancer, qui changent au fil du temps.

Définition : enregistrement alias

Enregistrement propre à Route 53, qui fait pointer un nom vers une ressource AWS (load balancer, distribution CloudFront) et suit automatiquement ses changements d'adresse.

Alias ou CNAME

Un alias fonctionne aussi à la racine du domaine (`utopios.example`), ce qu'un CNAME ne permet pas, et ses requêtes ne sont pas facturées. Avec un autre hébergeur DNS, on crée un CNAME vers le nom du load balancer.

Chiffrer jusqu'à l'application ?

Montage	Trajet	Quand le choisir
Terminaison sur l'ALB	HTTPS jusqu'au load balancer, HTTP ensuite, dans le réseau privé.	Le cas courant : simple, performant, un seul certificat.
Rechiffrement	HTTPS jusqu'au load balancer, puis nouvelle connexion HTTPS vers les cibles.	Exigence de chiffrement de bout en bout. Les cibles portent un certificat, qui peut être auto-signé : l'ALB ne le vérifie pas.
Transmission sans déchiffrement	Un NLB en TCP transmet le flux TLS tel quel ; l'application le déchiffre.	L'application doit voir le certificat du client, ou aucun intermédiaire ne doit lire le trafic.

Ce que le premier montage suppose

- Le trafic en clair ne circule que dans le VPC, entre le load balancer et des instances privées.
- `sg-app` n'accepte que `sg-alb` : personne d'autre ne peut parler aux instances.
- Les instances n'ont pas d'adresse publique.

Côté application. Derrière une terminaison TLS, l'application reçoit du HTTP. Pour construire des liens corrects et savoir que le client est bien en HTTPS, elle lit l'en-tête `X-Forwarded-Proto`. L'en-tête `Strict-Transport-Security`, renvoyé par l'application, demande aux navigateurs de ne plus jamais tenter HTTP.

Erreur	Symptôme	Correction
Certificat demandé dans une autre région que le load balancer	Introuvable dans la liste du listener.	Le redemander dans la bonne région.
Certificat pour CloudFront hors us-east-1	Introuvable dans CloudFront.	Le demander en us-east-1.
CNAME de validation jamais créé	État « Pending validation » sans fin.	Créer l'enregistrement dans la bonne zone.
CNAME de validation supprimé ensuite	Renouvellement en échec, certificat expiré.	Le laisser en place.
Port 443 absent de sg-alb	Délai dépassé en HTTPS.	Règle entrante 443.
Accès par le nom du load balancer	Alerte de certificat : le nom ne correspond pas.	Passer par le nom de domaine du certificat.
Listener HTTP laissé en transmission	Le site reste accessible en clair.	Le remplacer par une redirection.
Politique TLS ancienne	Audit défavorable.	Politique TLS 1.2 et 1.3.
Validation par e-mail	Certificat expiré faute d'avoir cliqué.	Validation DNS.

Ce qu'il faut retenir

- Un load balancer apporte disponibilité, montée en charge et point d'entrée stable.
- ALB : couche 7. Un listener écoute, ses règles choisissent un target group, dont les cibles sont sondées.
- Seules les cibles saines reçoivent du trafic ; le contrôle de santé se soigne.
- Le filtrage est chaîné : `sg-app` n'accepte que `sg-alb`.
- NLB : couche 4, adresses fixes, protocoles non HTTP, très hautes performances.
- HTTPS se termine sur le load balancer, avec un certificat ACM gratuit, validé par DNS et renouvelé automatiquement.
- On joint un load balancer par un nom, jamais par une adresse.

1. Quels sont les quatre composants d'un ALB ?

2. Que devient une cible déclarée « unhealthy » ?

3. Que signifie une erreur 504 ?

4. Pourquoi un ALB exige-t-il deux sous-réseaux ?

5. Citez deux cas où l'on choisit un NLB.

6. Dans quelle région demander le certificat d'un ALB ?

7. Pourquoi préférer la validation DNS ?

Cliquer sur une question pour afficher la réponse.

Élasticité, partie 1

L'Auto Scaling group

Laisser AWS maintenir le bon nombre d'instances : en ajouter quand la charge monte, en retirer quand elle baisse, remplacer celles qui tombent.

- L'élasticité en pratique
- Les trois ingrédients
- Capacité minimale, voulue, maximale
- Répartition entre zones
- Remplacement automatique
- Création et cycle de vie

Définition : élasticité

Capacité d'un système à ajouter puis à retirer des ressources automatiquement, pour suivre la charge réelle, à la hausse comme à la baisse.

Définition : Amazon EC2 Auto Scaling

Service qui maintient un nombre voulu d'instances, les remplace quand elles défont et fait varier ce nombre selon des règles. Il est gratuit : on ne paie que les instances.

Définition : Auto Scaling group (ASG)

Ensemble d'instances identiques gérées comme un tout : même modèle de lancement, mêmes règles de capacité et de mise à l'échelle.


Trois services rendus

- **Disponibilité** : une instance défaillante est remplacée sans intervention ; la perte d'une zone est compensée dans les autres.
- **Capacité** : le nombre d'instances suit la charge, sans surdimensionner pour le pic.
- **Coût** : on cesse de payer la nuit et le week-end ce qui ne sert qu'en journée.

Même avec une capacité fixe, un Auto Scaling group est utile : minimum, voulu et maximum à la même valeur, et le groupe se contente de remplacer ce qui tombe. C'est la façon la plus simple de rendre un service résistant aux pannes.

Mise à l'échelle horizontale. On ajoute des machines identiques, plutôt que d'en grossir une : pas de coupure, pas de plafond, et une panne n'emporte qu'une fraction de la capacité.

Schéma : les trois ingrédients



Quoi lancer

Le modèle de lancement, vu au chapitre « Volumes et images » : image, type, rôle, security group, user data. Le groupe en désigne une version.

Où lancer


Une liste de sous-réseaux, dans au moins deux zones. Le groupe y répartit les instances de façon équilibrée.

À qui les présenter

Un target group du load balancer : chaque instance lancée y est inscrite, chaque instance retirée en est désinscrite.

Schéma : capacité minimale, voulue, maximale

capacité voulue : 4, ce que le groupe maintient en ce moment



minimum : 2

jamais moins

maximum : 8

jamais plus : le plafond de coût

Définition : capacité minimale

Nombre d'instances en dessous duquel le groupe ne descend jamais. Elle garantit la disponibilité.

Définition : capacité voulue (desired)

Nombre d'instances que le groupe s'efforce de maintenir à l'instant présent. Ce sont les politiques qui la font varier.

Définition : capacité maximale

Nombre d'instances que le groupe ne dépasse jamais. Elle plafonne le coût.

Choisir les trois valeurs

Valeur	Comment la fixer	Exemple
Minimum	Ce qu'il faut pour rester disponible si une zone tombe : au moins deux, une par zone.	2
Maximum	Ce que l'on accepte de payer au pire, avec une marge au-dessus du pic connu.	8
Voulue	La valeur de départ. Ensuite, on la laisse aux politiques de mise à l'échelle.	2

Règles

- Toujours : $\text{minimum} \leq \text{voulue} \leq \text{maximum}$.
- Modifier la capacité voulue à la main reste possible : le groupe lance ou retire aussitôt.
- Avec une politique de mise à l'échelle, ne plus fixer la capacité voulue dans le code d'infrastructure : chaque déploiement la remettrait à sa valeur initiale.

Maximum trop bas. Le groupe cesse de grossir alors que la charge monte : c'est une panne par saturation. Une alarme sur « capacité voulue égale au maximum » prévient à temps.

Minimum à zéro. Possible pour un environnement de test ou un traitement par lots : le groupe s'éteint complètement quand rien ne tourne.

Schéma : la répartition entre zones

Situation normale : 4 instances, 2 par zone

Zone a



Zone b




Le groupe équilibre de lui-même entre les zones.

Zone a indisponible

Zone a

Indisponible

Zone b



2 instances relancées ici

La capacité voulue est rétablie dans la zone restante.

Lecture. Le groupe lance ses instances en les équilibrant entre les zones de ses sous-réseaux. Si une zone devient indisponible, il relance dans les autres ce qui manque pour atteindre la capacité voulue, puis rééquilibre quand la zone revient.

Dimensionner pour la perte d'une zone. Avec deux zones, chacune porte la moitié de la charge : la perte de l'une double la charge de l'autre le temps du remplacement. Avec trois zones, la perte n'est que d'un tiers.

Schéma : le remplacement automatique



Le groupe ne répare pas : il remplace.

C'est pour cela que rien d'unique ne doit se trouver sur une instance.

Contrôle de santé	Détecte
EC2 (par défaut)	La machine : matériel, réseau, système qui ne répond plus.
ELB (à activer)	L'application : le contrôle de santé du target group échoue.

Définition : délai de grâce (health check grace period)

Durée, après le lancement d'une instance, pendant laquelle le groupe ignore ses contrôles de santé, le temps qu'elle démarre.

Activer le contrôle ELB. Sans lui, une instance dont l'application est plantée mais dont le système tourne reste dans le groupe indéfiniment.

La vie d'une instance dans le groupe

Étape	Ce qui se passe	Réglage associé
Lancement	Le groupe crée l'instance depuis le modèle, dans la zone la moins fournie.	Modèle de lancement, sous-réseaux.
Démarrage	Le user data s'exécute ; l'instance n'est pas encore comptée comme prête.	Délai de grâce ; temps de préchauffage (warmup).
En service	Inscrite au target group, elle reçoit du trafic une fois déclarée saine.	Contrôle de santé du target group.
Choix pour le retrait	À la baisse, le groupe choisit quelle instance retirer : d'abord dans la zone la plus fournie, puis celle du modèle le plus ancien.	Politique de terminaison ; protection contre le retrait.
Retrait	Désinscrite du target group, elle termine ses requêtes en cours, puis est supprimée.	Délai de désinscription.

Définition : lifecycle hook

Point d'arrêt placé au lancement ou au retrait d'une instance, qui la met en attente le temps d'exécuter une action : finir une installation, vider des files, envoyer des journaux.

Délais à accorder. Le délai de grâce et le préchauffage doivent couvrir le temps réel de démarrage de l'application. Trop courts, le groupe supprime des instances qui allaient très bien et recommence sans fin ; trop longs, il réagit lentement.

Ligne de commande : créer un Auto Scaling group

\$ Prérequis : modèle de lancement user7-lt-web, sous-réseaux privés PRIV_A et PRIV_B, target group TG ; remplacer user7

1. Créer le groupe : 2 instances au départ, entre 2 et 6, sur deux zones, derrière le load balancer

```
aws autoscaling create-auto-scaling-group --auto-scaling-group-name user7-asg-web \
  --launch-template 'LaunchTemplateName=user7-lt-web,Version=$Default' \
  --min-size 2 --desired-capacity 2 --max-size 6 \
  --vpc-zone-identifiant "$PRIV_A,$PRIV_B" \
  --target-group-arns $TG \
  --health-check-type ELB --health-check-grace-period 120 \
  --tags Key=Name,Value=user7-web,PropagateAtLaunch=true Key=Owner,Value=user7,PropagateAtLaunch=true
```

2. Les instances du groupe : identifiant, zone, état, santé

```
aws autoscaling describe-auto-scaling-groups --auto-scaling-group-names user7-asg-web --output table \
  --query 'AutoScalingGroups[0].Instances[].[InstanceId,AvailabilityZone,LifecycleState,HealthStatus]'
```

3. Le journal du groupe : ce qu'il a fait, et pourquoi

```
aws autoscaling describe-scaling-activities --auto-scaling-group-name user7-asg-web --max-items 5 \
  --query 'Activities[].[StartTime,StatusCode,Description,Cause]' --output text
```

4. Changer la capacité voulue à la main

```
aws autoscaling set-desired-capacity --auto-scaling-group-name user7-asg-web --desired-capacity 3
```

5. Supprimer le groupe et toutes ses instances

```
aws autoscaling delete-auto-scaling-group --auto-scaling-group-name user7-asg-web --force-delete
```

Vérifier le remplacement. Supprimer à la main une instance du groupe, puis relire le journal : quelques secondes plus tard, le groupe constate l'écart avec la capacité voulue et en lance une nouvelle. Une instance d'un groupe ne se supprime donc pas « pour de bon » : il faut baisser la capacité, ou supprimer le groupe.

Élasticité, partie 2

Les politiques de mise à l'échelle

Dire au groupe quand grossir et quand maigrir : en suivant une mesure, ou en suivant l'horloge.

- Les façons de faire varier la capacité
- Le suivi de cible
- Choisir la métrique et la valeur
- La mise à l'échelle planifiée
- Combiner les politiques
- Déployer par remplacement

Les façons de faire varier la capacité


Méthode	Principe	Quand l'utiliser
Manuelle	On modifie soi-même la capacité voulue.	Essai, événement ponctuel.
Planifiée	La capacité change à des dates et heures fixées.	Charge connue d'avance : heures ouvrées, soldes, clôture mensuelle.
Suivi de cible	On fixe la valeur visée d'une métrique ; le groupe ajuste pour s'y tenir.	Le cas général : la politique à choisir par défaut.
Par paliers	À chaque seuil d'alarme franchi, un nombre d'instances défini est ajouté ou retiré.	Besoin de réactions différentes selon l'ampleur du dépassement.
Prédictive	AWS prévoit la charge d'après l'historique et lance les instances à l'avance.	Charge cyclique et régulière, démarrage lent des instances.

Définition : politique de mise à l'échelle (scaling policy)

Règle attachée à un Auto Scaling group, qui modifie sa capacité voulue en fonction d'une mesure ou d'un calendrier, sans jamais sortir de l'intervalle minimum-maximum.

Deux mots à connaître. « Scale out » : ajouter des instances. « Scale in » : en retirer. À ne pas confondre avec « scale up », qui désigne le passage à une machine plus puissante.

Schéma : le suivi de cible



Comme un thermostat : on fixe la valeur, le groupe ajuste le nombre d'instances.

Définition : politique de suivi de cible (target tracking)

Politique qui maintient une métrique moyenne du groupe proche d'une valeur fixée, en ajoutant ou retirant des instances. AWS crée et gère lui-même les alarmes nécessaires.

Pourquoi c'est la politique par défaut. Un seul nombre à choisir. Pas de seuils à régler, pas d'alarmes à écrire, et le calcul du nombre d'instances à ajouter est fait pour vous, proportionnellement à l'écart.

Choisir la métrique et la valeur cible

Métrique prédéfinie	Convient quand
Utilisation moyenne du processeur	La charge se traduit en calcul : le cas le plus courant.
Requêtes par cible du load balancer	Chaque requête coûte à peu près la même chose : très bon indicateur pour un site ou une API.
Trafic réseau entrant ou sortant moyen	L'application est limitée par le débit : transfert de fichiers, flux.
Métrique personnalisée	La vraie limite est ailleurs : longueur d'une file d'attente, connexions actives.

Qualités d'une bonne métrique


- Elle monte quand la charge monte.
- Elle **baisse quand on ajoute des instances** : c'est une moyenne par instance, pas un total.
- Elle réagit vite.

Choisir la valeur

- Processeur : 40 à 60 %. La marge restante absorbe la charge le temps que les nouvelles instances démarrent.
- Plus le démarrage est lent, plus la cible doit être basse.
- Une cible à 90 % ne laisse aucune marge : les clients subissent la lenteur avant que le renfort arrive.

Comportement asymétrique, et voulu. Le groupe ajoute vite, dès que la cible est dépassée quelques minutes, et retire lentement, après un quart d'heure environ sous la cible : mieux vaut payer un peu trop longtemps que retirer trop tôt et devoir relancer.

Schéma : la mise à l'échelle planifiée



Entre le minimum et le maximum, le suivi de cible continue d'ajuster.

Définition : action planifiée (scheduled action)

Modification programmée du minimum, du maximum ou de la capacité voulue d'un groupe, à une date précise ou selon une récurrence exprimée comme une tâche cron.

Ce qu'elle apporte au suivi de cible. Le suivi de cible réagit *après* la hausse, et les instances mettent quelques minutes à démarrer. Quand la hausse est prévisible, l'action planifiée met la capacité en place *avant* : à 9 heures, les clients trouvent des serveurs déjà prêts.

\$ Prérequis : le groupe user7-asg-web existe

1. Suivi de cible : maintenir le processeur moyen du groupe autour de 50 %

```
aws autoscaling put-scaling-policy --auto-scaling-group-name user7-asg-web \
  --policy-name cpu-50 --policy-type TargetTrackingScaling \
  --target-tracking-configuration \
  '{"PredefinedMetricSpecification":{"PredefinedMetricType":"ASGAverageCPUUtilization"},"TargetValue":50.0}'
```

2. Actions planifiées : monter le minimum à 4 en semaine à 7 h, le redescendre à 2 à 20 h (heure de Paris)

```
aws autoscaling put-scheduled-update-group-action --auto-scaling-group-name user7-asg-web \
  --scheduled-action-name matin --recurrence "0 7 * * 1-5" --time-zone "Europe/Paris" --min-size 4
aws autoscaling put-scheduled-update-group-action --auto-scaling-group-name user7-asg-web \
  --scheduled-action-name soir --recurrence "0 20 * * 1-5" --time-zone "Europe/Paris" --min-size 2
```

3. Ce qui est en place

```
aws autoscaling describe-policies --auto-scaling-group-name user7-asg-web \
  --query 'ScalingPolicies[][PolicyName,PolicyType,TargetTrackingConfiguration.TargetValue]' --output table
aws autoscaling describe-scheduled-actions --auto-scaling-group-name user7-asg-web \
  --query 'ScheduledUpdateGroupActions[][ScheduledActionName,Recurrence,MinSize]' --output table
```

4. Provoquer une montée en charge pour observer (sur une instance du groupe, par Session Manager)

```
# sudo dnf -y install stress-ng && stress-ng --cpu 2 --timeout 600
```

Lire une récurrence. Minute, heure, jour du mois, mois, jour de la semaine :

0 7 * * 1-5 signifie « à 7 h 00, du lundi au vendredi ». Sans fuseau précisé, l'heure est en UTC.

Ne pas modifier les alarmes que le suivi de cible crée dans CloudWatch : elles lui appartiennent, et il les recrée ou les ajuste lui-même.

Combiner les politiques

Politique	Rôle dans l'ensemble
Minimum et maximum	Le cadre : disponibilité garantie, coût plafonné.
Actions planifiées	Déplacent le cadre selon l'horloge : plus de capacité en journée, moins la nuit.
Suivi de cible	Ajuste en continu à l'intérieur du cadre, d'après la charge réelle.
Prédictive	Anticipe les cycles réguliers, en complément du suivi de cible.

Recette de départ. Minimum 2 sur deux zones ; maximum fixé d'après le budget ; un suivi de cible sur le processeur à 50 % ; contrôle de santé ELB. On affine ensuite avec les mesures.

Comment elles s'accordent

- Plusieurs politiques peuvent agir sur le même groupe.
- Quand elles demandent des capacités différentes, la **plus élevée** l'emporte : la disponibilité prime.
- Une action planifiée qui change le minimum ne supprime rien si le suivi de cible réclame davantage.

Avec les modes d'achat. Un groupe peut mélanger instances à la demande et Spot, et plusieurs types d'instance : la base à la demande, couverte par un Savings Plan, et le complément en Spot.

Observer. Le journal d'activité du groupe explique chaque décision : « an alarm triggered policy cpu-50, changing the desired capacity from 2 to 3 ». C'est la première chose à lire quand le groupe ne fait pas ce que l'on attend.

Schéma : déployer par remplacement



Déployer, c'est remplacer les instances, pas les modifier.

En cas de problème : retour à la version précédente du modèle, par le même mécanisme.

\$ Prérequis : une nouvelle version du modèle de lancement est la version par défaut

```
aws autoscaling start-instance-refresh \
  --auto-scaling-group-name user7-asg-web \
  --preferences '{"MinHealthyPercentage":90,"InstanceWarmup":120}'

aws autoscaling describe-instance-refreshes \
  --auto-scaling-group-name user7-asg-web \
  --query 'InstanceRefreshes[0].[Status,PercentageComplete]'
```

Définition : instance refresh

Opération d'un Auto Scaling group qui remplace progressivement toutes ses instances par de nouvelles, lancées avec la version courante du modèle, en gardant un pourcentage minimal de capacité saine.

Le groupe remplace d'abord quelques instances, attend qu'elles soient saines, puis continue. Si elles ne le deviennent pas, l'opération s'arrête ; un retour arrière automatique peut être activé.

Erreur	Symptôme	Correction
Délai de grâce plus court que le démarrage	Instances lancées puis supprimées en boucle.	Allonger le délai ; accélérer le démarrage par une AMI préparée.
Contrôle de santé EC2 seul	Instances à l'application plantée, jamais remplacées.	Type de contrôle ELB.
Chemin de santé qui dépend de la base	Une panne de base fait remplacer toutes les instances.	Contrôle limité à l'instance elle-même.
Maximum atteint	Lenteur sous charge, aucun ajout.	Relever le maximum ; alarme sur ce cas.
Cible trop haute	Renfort qui arrive après la saturation.	Baisser la cible ; action planifiée avant les pointes connues.
Capacité voulue figée dans le code d'infrastructure	Chaque déploiement annule la mise à l'échelle.	Ne déclarer que minimum et maximum.
Instance modifiée à la main	Changement perdu au premier remplacement.	Modifier l'image ou le modèle, puis remplacer.
Un seul sous-réseau	Aucune résistance à la perte d'une zone.	Sous-réseaux de deux zones au moins.
Quota de vCPU ou adresses du sous-réseau épuisés	Lancements en échec, visibles dans le journal.	Hausse de quota ; sous-réseaux plus larges.

Élasticité, partie 3

Concevoir sans état

L'Auto Scaling supprime des instances à tout moment. Il ne fonctionne que si aucune d'elles ne détient quoi que ce soit d'irremplaçable.

- Avec état, sans état
- Ce qui ne doit pas rester sur l'instance
- Les sessions des utilisateurs
- Où placer l'état
- L'arrêt propre
- Le test de l'instance jetable

Définition : sans état (stateless)

Se dit d'un composant qui ne conserve localement aucune donnée dont dépendrait une requête ultérieure. Deux exemplaires du composant sont interchangeables.

Définition : avec état (stateful)

Se dit d'un composant qui garde localement des données nécessaires à la suite : sessions, fichiers, base. Le perdre, c'est perdre ces données.

L'état existe toujours. Concevoir sans état ne consiste pas à le supprimer, mais à le **sortir des instances** pour le confier à des services faits pour le conserver.

Pourquoi l'élasticité l'exige


- **À la baisse**, le groupe supprime des instances : ce qu'elles seules détenaient disparaît.
- **À la hausse**, les nouvelles instances doivent pouvoir servir n'importe quel client aussitôt.
- **En cas de panne**, une instance est remplacée par une instance vierge.
- **Au déploiement**, toutes les instances sont remplacées.
- **En Spot**, AWS reprend une instance avec deux minutes de préavis.

Le symptôme d'une application à état. Des utilisateurs déconnectés « au hasard », des fichiers visibles une fois sur deux, des résultats différents selon le serveur qui répond.

Ce qui ne doit pas rester sur l'instance

État	Problème s'il reste local	Où le placer
Sessions des utilisateurs	Déconnexion à chaque retrait d'instance.	Cache partagé (ElastiCache), table DynamoDB, ou jeton signé côté client.
Fichiers déposés par les utilisateurs	Présents sur une seule instance, puis perdus.	Amazon S3 ; Amazon EFS si un système de fichiers partagé est indispensable.
Données métier	Perte de données.	Base gérée : RDS, Aurora, DynamoDB.
Journaux	Disparaissent avec l'instance, au moment où l'on en a besoin.	CloudWatch Logs, envoyés en continu par un agent.
Configuration et secrets	Instances différentes les unes des autres.	Parameter Store, Secrets Manager, lus au démarrage.
Tâches planifiées (cron)	Exécutées autant de fois qu'il y a d'instances, ou jamais.	EventBridge Scheduler, qui déclenche une seule exécution.
Travaux en file d'attente locale	Perdus au retrait.	File gérée : Amazon SQS.
Code et dépendances	Versions divergentes après des mises à jour manuelles.	AMI et modèle de lancement.

Ce qui peut rester local. Tout ce qui se reconstruit sans dommage : cache en mémoire, fichiers temporaires, résultats intermédiaires. La question n'est pas « y a-t-il des données sur l'instance ? », mais « que perd-on si elle disparaît maintenant ? ».




Lecture. Les instances du groupe ne font que calculer : elles reçoivent une requête, lisent et écrivent l'état dans des services extérieurs, répondent. Chacune peut traiter n'importe quelle requête de n'importe quel client, et disparaître sans que personne le remarque. Les services de droite, eux, sont conçus pour durer : répliqués, sauvegardés, gérés par AWS.

Sans état


Schéma : le cas des sessions

Session gardée en mémoire sur l'instance



Léa est déconnectée, son panier est perdu.
Chaque retrait d'instance touche des clients.

Session dans un cache partagé



N'importe quelle instance sert Léa.
Une instance peut disparaître sans effet.

Solution	Principe
Cache partagé	La session est dans ElastiCache ou DynamoDB ; le navigateur ne garde qu'un identifiant.
Jeton signé	La session est dans un jeton (JWT) détenu par le client et vérifié par n'importe quelle instance.
Sessions persistantes du load balancer	Un client retourne vers la même instance. Un palliatif : la session se perd quand même au retrait.

Les sessions persistantes ne rendent pas une application sans état.
Elles masquent le problème tant que rien ne bouge, et déséquilibrent la charge : les nouvelles instances ne reçoivent que les nouveaux clients.

L'arrêt propre, et le test de l'instance jetable

Ce qui se passe au retrait

1. L'instance est désinscrite du target group : plus de nouvelles requêtes.
2. Elle dispose du délai de désinscription pour terminer celles en cours.
3. Le système reçoit un signal d'arrêt (SIGTERM).
4. L'instance est supprimée.

Définition : arrêt propre (graceful shutdown)

Capacité d'une application à réagir au signal d'arrêt en terminant ses traitements en cours, en fermant ses connexions et en vidant ses tampons avant de s'éteindre.

Pour un traitement plus long que le délai, un lifecycle hook retient l'instance le temps nécessaire.

Le test

« Puis-je supprimer n'importe quelle instance, à n'importe quel moment, sans que personne ne le remarque ? »

- Aucun utilisateur déconnecté ?
- Aucun fichier ni journal perdu ?
- Aucune requête en erreur ?
- L'instance de remplacement est-elle prête sans intervention ?

Si une réponse est non, l'application n'est pas encore prête pour l'Auto Scaling.

Faire le test pour de vrai. En préproduction, supprimer une instance au hasard pendant un test de charge. C'est le seul moyen de savoir, et c'est exactement ce que l'Auto Scaling fera en production.

Erreur	Conséquence	Correction
Sessions en mémoire du serveur d'application	Déconnexions à chaque variation du groupe.	Cache partagé ou jeton signé.
Fichiers déposés écrits sur le disque local	Fichiers introuvables selon l'instance qui répond.	Amazon S3.
Journaux consultés sur l'instance	Perdus avec elle ; diagnostic impossible après coup.	Agent CloudWatch, envoi en continu.
Tâche cron sur chaque instance	Traitement exécuté en double, ou en triple.	Planificateur extérieur, une seule exécution.
Correctif appliqué à la main sur les instances	Disparaît au remplacement suivant.	Nouvelle image, nouveau modèle, remplacement.
Base de données dans le groupe	Perte de données à la première baisse.	Base gérée, hors du groupe.
Application qui ignore le signal d'arrêt	Requêtes coupées au retrait.	Arrêt propre ; délai de désinscription suffisant.
Compter sur les sessions persistantes	Problème masqué, charge déséquilibrée.	Sortir réellement l'état.

Bétail, pas animaux de compagnie. L'image est connue : un animal de compagnie a un nom, on le soigne quand il est malade ; une bête du troupeau porte un numéro, on la remplace. Les instances d'un Auto Scaling group relèvent de la seconde catégorie.

Ce qu'il faut retenir

- Un Auto Scaling group réunit un modèle de lancement, des sous-réseaux sur plusieurs zones et, le plus souvent, un target group.
- Minimum pour la disponibilité, maximum pour le coût, capacité voulue entre les deux.
- Le groupe remplace les instances défaillantes et rééquilibre entre les zones.
- Suivi de cible : on fixe une valeur, le groupe ajuste. C'est la politique par défaut.
- Action planifiée : la capacité est en place avant une hausse connue.
- On déploie en remplaçant les instances, pas en les modifiant.
- Tout cela suppose des instances sans état : rien d'irremplaçable n'y réside.

1. Quels sont les trois ingrédients d'un Auto Scaling group ?

2. À quoi servent le minimum et le maximum ?

3. Pourquoi activer le contrôle de santé ELB ?

4. Que règle-t-on dans une politique de suivi de cible ?


5. Quel est l'avantage d'une action planifiée ?

6. Où placer les sessions des utilisateurs ?

7. Quel est le test de l'instance jetable ?

Cliquer sur une question pour afficher la réponse.

Schéma : UtopiosShop après ces quatre chapitres



Entrée

Un nom de domaine, un certificat ACM, un Application Load Balancer sur deux zones. HTTP est redirigé vers HTTPS.

Calcul

Un Auto Scaling group sur deux zones : instances privées et sans état, lancées depuis une AMI et un modèle de lancement, ajustées par un suivi de cible.

Données

Volumes gp3 chiffrés, snapshots automatiques avec durée de conservation. La base, dans les sous-réseaux isolés.

#	Pratique	Chapitre
1	Instances privées, sans clé SSH ni port 22 : Session Manager.	L'instance EC2
2	Un rôle par application ; aucune clé d'accès sur une instance ; IMDSv2 exigé.	L'instance EC2
3	Aucun secret dans le user data ; un script court et idempotent.	L'instance EC2
4	Type choisi d'après les mesures ; éteindre ce qui ne sert pas, puis engager la base.	L'instance EC2
5	Volumes gp3, chiffrés par défaut, données séparées du système.	Volumes et images
6	Snapshots automatiques, conservation définie, restauration testée.	Volumes et images
7	Une image de référence reconstruite régulièrement, et un modèle de lancement versionné.	Volumes et images
8	Au moins deux instances, dans deux zones, derrière un load balancer.	Répartition de charge
9	Un contrôle de santé dédié, qui reflète l'état réel de l'application.	Répartition de charge
10	HTTPS partout, certificat ACM validé par DNS, HTTP redirigé.	Répartition de charge
11	Un Auto Scaling group même à capacité fixe ; suivi de cible, contrôle de santé ELB.	Élasticité
12	Des instances sans état : rien d'irremplaçable sur une machine.	Élasticité

Fil conducteur. Une instance n'est pas un serveur que l'on soigne, mais un exemplaire que l'on peut jeter : sa définition est dans l'image et le modèle, ses données sont ailleurs, et le load balancer fait oublier son remplacement.

Terme	Définition
Instance	Serveur virtuel EC2.
AMI	Image à partir de laquelle une instance est créée.
Type d'instance	Combinaison de processeur, mémoire et réseau : famille, génération, taille.
Paire de clés	Clé publique sur l'instance, clé privée chez l'utilisateur, pour SSH.
User data	Script exécuté une fois, au premier démarrage.
IMDS	Service de métadonnées local à l'instance.
Session Manager	Accès terminal sans port entrant ni clé.
Instance profile	Conteneur qui attache un rôle à une instance.
Spot	Instance à prix réduit, interruptible avec deux minutes de préavis.
Savings Plan	Engagement de dépense horaire contre une remise.
Volume EBS	Disque en réseau, persistant, lié à une zone.
IOPS, débit	Opérations par seconde ; volume de données par seconde.
Snapshot	Sauvegarde incrémentale d'un volume, à un instant donné.
Modèle de lancement	Recette versionnée du lancement d'une instance.

Terme	Définition
Load balancer	Répartit les connexions entre plusieurs cibles saines.
ALB	Load balancer de couche 7, pour HTTP et HTTPS.
NLB	Load balancer de couche 4, pour TCP et UDP, à adresses fixes.
Listener	Écoute sur un protocole et un port, et applique des règles.
Règle	Conditions et action appliquées à une requête.
Target group	Ensemble de cibles, avec port et contrôle de santé.
Contrôle de santé	Sonde périodique qui décide si une cible reçoit du trafic.
Délai de désinscription	Temps laissé aux requêtes en cours avant le retrait d'une cible.
X-Forwarded-For	En-tête qui porte l'adresse réelle du client.
TLS	Protocole de chiffrement et d'authentification des connexions.
Certificat	Preuve signée qu'une clé appartient à un nom de domaine.
ACM	Service qui délivre et renouvelle les certificats.
Terminaison TLS	Déchiffrement de HTTPS sur le load balancer.
Alias	Enregistrement Route 53 pointant vers une ressource AWS.

Terme	Définition
Élasticité	Ajout et retrait automatiques de ressources selon la charge.
Auto Scaling group	Ensemble d'instances identiques gérées comme un tout.
Capacité minimale, maximale	Bornes que le groupe ne franchit jamais.
Capacité voulue	Nombre d'instances que le groupe maintient à l'instant présent.
Scale out, scale in	Ajouter des instances ; en retirer.
Politique de mise à l'échelle	Règle qui fait varier la capacité voulue.
Suivi de cible	Politique qui maintient une métrique proche d'une valeur fixée.
Action planifiée	Changement de capacité programmé à une date ou selon une récurrence.
Délai de grâce	Temps laissé à une instance neuve avant de vérifier sa santé.
Lifecycle hook	Mise en attente d'une instance au lancement ou au retrait.
Instance refresh	Remplacement progressif de toutes les instances d'un groupe.
Sans état	Qui ne conserve localement rien d'irremplaçable.
Arrêt propre	Fin des traitements en cours avant extinction.

Sujet	Documentation officielle
Amazon EC2	Amazon EC2 User Guide
Types d'instance	aws.amazon.com/ec2/instance-types
Session Manager	AWS Systems Manager Session Manager
Amazon EBS	Amazon EBS User Guide
Load balancers	Application Load Balancers Guide
Certificats	AWS Certificate Manager User Guide
Tarifs	aws.amazon.com/ec2/pricing
Auto Scaling	Amazon EC2 Auto Scaling User Guide

Icônes. Les icônes des schémas proviennent du jeu officiel « AWS Architecture Icons », publié par AWS pour la réalisation de schémas d'architecture.

Ce qui est acquis

- Lancer, configurer et administrer une instance sans rien exposer.
- Stocker, sauvegarder, et fabriquer une image.
- Placer les instances derrière un load balancer, en HTTPS.
- Laisser un Auto Scaling group ajuster et réparer la flotte.

Suite du parcours : le stockage

- Amazon S3 : buckets, classes de stockage, accès.
- Les fichiers partagés et la diffusion de contenu.

C'est là que sera placé l'état que l'on vient de sortir des instances : fichiers, sauvegardes, contenus statiques.

Avant de quitter. Supprimer d'abord les Auto Scaling groups, sinon ils relancent les instances. Puis volumes détachés, snapshots, Elastic IP et load balancers.